

**TÜRKİYE CUMHURİYETİ**  
**YILDIZ TEKNİK ÜNİVERSİTESİ**  
**BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**



**BİR DUYGU ANALİZ YÖNTEMİ OLARAK METİNDEN**  
**EMOJİ TAHMİNİ**

19011010 — Beyda Güler  
20011055 — Şeymanur Korkmaz

**BİLGİSAYAR PROJESİ**

Danışman  
Doç. Dr. Öğr. Üyesi Ali Can KARACA

Haziran, 2023



## TEŞEKKÜR

---

Projemizde, yolculuğumuz boyunca bize değerli rehberlikleriyle özverili bir şekilde destek olan, ihtiyacımız olduğunda kıymetli vaktini bizden esirgemeyen ve kariyerimizi şekillendirdiğimiz bu süreçte bilgi ve tecrübesiyle yolumuzu aydınlatan saygıdeğer danışmanımız Doç. Dr. Ali Can Karaca'ya en içten teşekkürlerimizi sunarız.

Ayrıca çalışmamız boyunca desteğini esirgemeyen ve sorunlarımıza sabırla çözüm üreten Arş. Gör. Kübra Adalı'ya yardımları için teşekkür ederiz.

Beyda Güler  
Şeymanur Korkmaz

# İÇİNDEKİLER

---

|   |             |
|---|-------------|
| <b>SİMGE LİSTESİ</b>                                | <b>v</b>    |
| <b>KISALTMA LİSTESİ</b>                             | <b>vi</b>   |
| <b>ŞEKİL LİSTESİ</b>                                | <b>viii</b> |
| <b>TABLO LİSTESİ</b>                                | <b>ix</b>   |
| <b>ÖZET</b>   | <b>x</b>    |
| <b>ABSTRACT</b>                                     | <b>xi</b>   |
| <b>1 Giriş</b>                                      | <b>1</b>    |
| 1.1 Doğal Dil İşleme . . . . .                      | 1           |
| 1.2 Doğal Dil İşlemenin Uygulama Alanları . . . . . | 2           |
| 1.3 Projenin Amacı . . . . .                        | 3           |
| 1.4 Veri Seti . . . . .                             | 4           |
| <b>2 Ön İnceleme</b>                                | <b>8</b>    |
| 2.1 Projeye Olan İhtiyaç . . . . .                  | 8           |
| 2.2 Proje Kapsamı . . . . .                         | 8           |
| <b>3 Fizibilite</b>                                 | <b>9</b>    |
| 3.1 Yasal Fizibilite . . . . .                      | 9           |
| 3.2 Teknik Fizibilite . . . . .                     | 9           |
| 3.2.1 Yazılım Fizibilitesi . . . . .                | 9           |
| 3.2.2 Donanım Fizibilitesi . . . . .                | 9           |
| 3.3 İş Gücü ve Zaman Fizibilitesi . . . . .         | 10          |
| 3.4 Ekonomik Fizibilite . . . . .                   | 10          |
| <b>4 Sistem Analizi</b>                             | <b>11</b>   |
| 4.1 Gereksinim Analizi . . . . .                    | 11          |
| 4.2 Hedefler . . . . .                              | 11          |
| 4.3 Performans Metrikleri . . . . .                 | 12          |

|          |  |           |
|----------|--|-----------|
| <b>5</b> | <b>Sistem Tasarımı</b>                               | <b>13</b> |
| 5.1      | Yazılım Tasarımı . . . . .                           | 13        |
| 5.1.1    | Ön İşleme . . . . .                                  | 14        |
| 5.1.2    | Veri Sayısallaştırma . . . . .                       | 14        |
| 5.1.3    | Veri Örneklerinin Boyutlarının Eşitlenmesi . . . . . | 14        |
| 5.1.4    | Yeniden Örnekleme . . . . .                          | 14        |
| 5.1.5    | Modelleme . . . . .                                  | 15        |
| <b>6</b> | <b>Uygulama</b>                                      | <b>20</b> |
| 6.1      | Modellerin Özellikleri . . . . .                     | 20        |
| 6.2      | Modellerin Eğitilmesi . . . . .                      | 20        |
| <b>7</b> | <b>DeneySEL Sonuçlar</b>                             | <b>22</b> |
| 7.1      | Eğitim, Doğrulama ve Test Ayrımı . . . . .           | 22        |
| 7.2      | Model Sonuçları . . . . .                            | 22        |
| 7.2.1    | LSTM . . . . .                                       | 22        |
| 7.2.2    | BLSTM . . . . .                                      | 23        |
| 7.2.3    | BERT . . . . .                                       | 23        |
| 7.2.4    | İki Aşamalı Sınıflandırma . . . . .                  | 23        |
| <b>8</b> | <b>Performans Analizi</b>                            | <b>25</b> |
| 8.1      | LSTM . . . . .                                       | 25        |
| 8.2      | BLSTM . . . . .                                      | 27        |
| 8.3      | BERT . . . . .                                       | 29        |
| 8.4      | İki Aşamalı Sınıflandırma (BERT) . . . . .           | 31        |
| 8.5      | Emoji Tahminleri . . . . .                           | 34        |
| 8.6      | Emoji Sınıflarının Birleştirilmesi . . . . .         | 35        |
| <b>9</b> | <b>Sonuç</b>   | <b>38</b> |
| 9.1      | GloVe . . . . .                                      | 38        |
| 9.2      | Keras . . . . .                                      | 40        |
| 9.3      | Word2Vec . . . . .                                   | 41        |
| 9.4      | BERT . . . . .                                       | 42        |
| 9.5      | İki Aşamalı Sınıflandırma . . . . .                  | 43        |
| 9.6      | Değerlendirme . . . . .                              | 44        |
|          | <b>Referanslar</b>                                   | <b>45</b> |
|          | <b>Özgeçmiş</b>                                      | <b>47</b> |

## SİMGE LİSTESİ

---

|    |               |
|----|---------------|
| %  | Yüzde İşareti |
| #  | Hashtag       |
| TL | Türk Lirası   |

## KISALTMA LİSTESİ

---

|       |   |
|-------|---|
| avg   | average   |
| AI    | Artificial Intelligence                                 |
| BERT  | Bidirectional Encoder Representations from Transformers |
| CBOW  | Continuous Bag of Words                                 |
| CLS   | Classification  |
| CPU   | Central Processing Unit                                 |
| CRF   | Conditional Random Field                                |
| DL    | Deep Learning   |
| GLOVE | Global Vectors for Word Representation                  |
| GPU   | Graphical User Interface                                |
| HTML  | Hyper Text Markup Language                              |
| LSTM  | Long Short-Term Memory                                  |
| BLSTM | Bidirectional Long Short-Term Memory                    |
| ML    | Machine Learning  |
| MLM   | Masked Language Modeling                                |
| NLP   | Natural Language Processing                             |
| NSP   | Next Sentence Prediction                                |
| RAM   | Random Access Memory                                    |
| RNN   | Recurrent Neural Networks                               |
| RT    | Retweet   |
| SEP   | Separator   |
| ROS   | Random Over Sampling                                    |
| SMOTE | Synthetic Minority Over-sampling Technique              |

|          |   |
|----------|---|
| TF-IDF   | Term Frequency — Inverse Document Frequency |
| TPU      | Tensor Processing Units                     |
| Word2Vec | Word to Vector                              |



## ŞEKİL LİSTESİ

---

|            |   |    |
|------------|---|----|
| Şekil 1.1  | Doğal Dil İşlemenin Bilgisayar Bilimindeki yeri [2] . . . . . | 1  |
| Şekil 1.2  | Emojilerin Veri Setinde Dağılımı . . . . .                    | 5  |
| Şekil 3.1  | İş / Zaman Çizelgesi . . . . .                                | 10 |
| Şekil 5.1  | Yazılım Tasarımı Akış Diyagramı . . . . .                     | 13 |
| Şekil 5.2  | Standart RNN [14] . . . . .                                   | 16 |
| Şekil 5.3  | LSTM [14] . . . . .   | 16 |
| Şekil 5.4  | BLSTM [16] . . . . .  | 17 |
| Şekil 5.5  | BERT [16] . . . . .   | 18 |
| Şekil 5.6  | BERT Girdi Gösterimi [17] . . . . .                           | 18 |
| Şekil 8.1  | LSTM F-1 Skor Sonuçları . . . . .                             | 25 |
| Şekil 8.2  | LSTM Confusion Matrix . . . . .                               | 26 |
| Şekil 8.3  | BLSTM F-1 Skor Sonuçları . . . . .                            | 27 |
| Şekil 8.4  | BLSTM Confusion Matrix . . . . .                              | 28 |
| Şekil 8.5  | BERT F-1 Skor Sonuçları . . . . .                             | 29 |
| Şekil 8.6  | BERT Confusion Matrix . . . . .                               | 30 |
| Şekil 8.7  | BERT İki Aşamalı Sınıflandırma F-1 Skor Sonuçları . . . . .   | 31 |
| Şekil 8.8  | BERT Tek Aşamalı Sınıflandırma Confusion Matrix . . . . .     | 32 |
| Şekil 8.9  | BERT İki Aşamalı Sınıflandırma Confusion Matrix . . . . .     | 33 |
| Şekil 8.10 | BLSTM Emoji Tahminleri . . . . .                              | 34 |
| Şekil 8.11 | Emoji Tablosu . . . . .                                       | 35 |
| Şekil 8.12 | Düzenlenmiş Emoji Tablosu . . . . .                           | 35 |
| Şekil 8.13 | Birleştirilmiş Sınıflar ile BERT F-1 Skor Sonuçları . . . . . | 36 |
| Şekil 8.14 | Birleştirilmiş Sınıflar ile BERT Confusion Matrix . . . . .   | 37 |
| Şekil 9.1  | Yarışmaya Katılan Diğer Takımların F-1 Skorları . . . . .     | 44 |

## TABLO LİSTESİ

---

|           |  |    |
|-----------|--|----|
| Tablo 1.1 | Nisan 2022 İtibariyle Bir İnternet Dakikasında Medya Kullanımı                 | 4  |
| Tablo 1.2 | Veri Setinin Ham Hali . . . . .  | 6  |
| Tablo 1.3 | Veri Setinin Temizlenmiş Hali . . . . .  | 6  |
| Tablo 3.1 | Ekonomik Fizibilite Tablosu . . . . .  | 10 |
| Tablo 7.1 | LSTM Modelleri için F-1 Score Sonuçları . . . . .                              | 22 |
| Tablo 7.2 | BLSTM Modelleri için F-1 Score Sonuçları . . . . .                             | 23 |
| Tablo 7.3 | BERT Modelleri için F-1 Score Sonuçları . . . . .                              | 23 |
| Tablo 7.4 | İki Aşamalı Sınıflandırma için F-1 Score Sonuçları . . . . .                   | 24 |
| Tablo 9.1 | GloVe Gömme Modeli ile F-1 Skor Sonuçlarının Karşılaştırılması                 | 38 |
| Tablo 9.2 | Keras Gömme Modeli ile F-1 Skor Sonuçlarının Karşılaştırılması                 | 40 |
| Tablo 9.3 | Word2Vec Gömme Modeli ile F-1 Skor Sonuçlarının<br>Karşılaştırılması . . . . . | 41 |
| Tablo 9.4 | BERT ile F-1 Skor Sonuçlarının Karşılaştırılması . . . . .                     | 42 |
| Tablo 9.5 | İki Aşamalı Sınıflandırma ile F-1 Skor Sonuçlarının Karşılaştırılması          | 43 |

# BİR DUYGU ANALİZ YÖNTEMİ OLARAK METİNDEN EMOJİ TAHMİNİ

Beyda Güler  
Şeymanur Korkmaz

Bilgisayar Mühendisliği Bölümü  
Bilgisayar Projesi

Danışman: Doç. Dr. Öğr. Üyesi Ali Can KARACA

Günümüz dünyasında dijitalleşmenin geldiği son noktaya bakıldığında verinin inanılmaz boyutlara ulaştığı görülmektedir. Sosyal mecralar aracılığıyla her saniye milyonlarca yeni veri girişi söz konusu olmaktadır. Bu durum, verilerin işlenmesi ve yorumlanması ihtiyacını doğurmuştur. Verilerin insanın birinci elden yorumlayamacağı kadar büyük boyutta ve karmaşık halde olması sebebiyle bu ihtiyacın giderilmesi için makine öğrenmesi ve derin öğrenme yöntemlerine başvurulmaktadır.

Söz konusu verinin metin veya ses olması halinde devreye yapay zekanın bir alt kolu olan doğal dil işleme girmektedir. Doğal dil işleme, makineye insan dilinin tanıtılması ve sonrasında da tekrar insan tarafından anlaşılır biçimde bir çıktı üretilmesi sürecini takip eder.

Yazılı metinler jest, mimik, ses tonu gibi öğeler barındırmadığı için duygudan kısmen yoksundur. Emojiler, bu eksikliği bir nebze gidererek metinlerin duygu iletiminin daha başarılı yapılmasına katkıda bulunan unsurlardır.

Bu çalışmamızda salt metin içeren tweet'lere çeşitli makine öğrenmesi ve derin öğrenme algoritmaları kullanarak emoji tahmini yapılmaktadır.

**Anahtar Kelimeler:** doğal dil işleme, makine öğrenmesi, derin öğrenme, duygu analizi, emoji tahmini.

## ABSTRACT

---

# EMOJI PREDICTION AS A SENTIMENT ANALYSIS METHOD

Beyda Güler  
Şeymanur Korkmaz

Department of Computer Engineering  
Computer Project

Advisor: Assoc. Dr. Ali Can KARACA

When we look at the last point of digitalisation in today's world, it is seen that the data has reached an incredible size. There are millions of new data entries every second through social media. This situation has led to the need for processing and interpretation of data. Machine learning and deep learning methods are used to meet this need due to the fact that the data is too large and complex for humans to interpret first-hand.

If the data is text or voice, natural language processing, a sub-branch of artificial intelligence, comes into play. Natural language processing follows the process of introducing human language to the machine and then producing an output in a human-understandable form.


Texts are partially devoid of emotion because they do not contain elements such as gesture, mimic, tone of voice, etc. Emojis are the elements that contribute to emotion transmission of texts by overcoming this deficiency to some extent.

In this study, we predict emoji for text-only tweets using various machine learning and deep learning algorithms.

**Keywords:** natural language processing, machine learning, deep learning, sentiment analysis, emoji prediction.

### 1.1 Doğal Dil İşleme

Doğal dil işleme (NLP), yapay zekanın (AI) bir koludur ve bilgisayarların, insan dilini kavramasını, üretmesini ve idare etmesini sağlar [1]. Bilgisayar dünyasında, makine dilleri yani programlama dilleri yani programlama dilleri ve doğal diller olmak üzere iki tür dil vardır. Doğal dil işleme, doğal dillerin kurallı yapısının çözümlenerek anlaşılmasını veya yeniden üretilmesini amaçlar. Yapay zekanın bir kolu olan doğal dil işlemenin bilgisayar bilimindeki yeri Şekil 1.1’de verilmiştir. Şekilde de görüldüğü üzere doğal dil işlemenin de bilgi elde etme, otomatik çeviri, dil analizi gibi çeşitli alt alanları bulunmaktadır.



Şekil 1.1 Doğal Dil İşlemenin Bilgisayar Bilimindeki yeri [2]

Doğal dil işleme sayesinde bilgisayarlar, insan dilini anlar ve yine insanın anlayabileceği şekilde çıktı verir. Girdilerin türüne göre doğal dil işleme, ses ve metinler olarak iki kategoriye ayrılır. Ses üzerinden çalışıldığında genellikle takip edilen yaklaşım sesin yazılı hale getirilmesi ve elde edilen metin üzerinden metin işleme (text processing) uygulanması şeklindedir.

Günlük hayatta birçok insan bu sistemlerle farkında olarak veya olmayarak

etkileşimde bulunmaktadır. Örneğin Apple-Siri, Google-Asistan, chatbot ve sanal kişisel asistan sistemlerinin arkasında doğal dil işleme teknolojisi yatmaktadır. Doğal dil işlemenin faydaları günlük hayatta bizlere sağladığı bireysel kolaylıklarla sınırlı değildir. Pazarlama alanındaki araştırma çalışmalarını da oldukça hızlandırmış ve özel sektörde çığır açacak düzeyde müşteri ihtiyaçlarını belirlemede önemli bir rol oynamıştır [3].

Doğal dil işleme çalışmalarının tarihsel gelişimine baktığımızda Sembolik NLP, İstatiksel NLP ve Nöral NLP olmak üzere üç aşama karşımıza çıkmaktadır [3]. Nöral NLP’de kullanılan Yapay Sinir Ağları (Artificial Neural Networks) büyük ölçekli verinin işlenmesinde büyük yol katedilmesini sağlamıştır. Derin öğrenme modelleri, klasik makine öğrenmesi modellerinden çok daha iyi bir genelleme sağladıkları için doğal dil işleme uygulamalarında en popüler yöntemler arasında yer almaktadır.

Doğal dil işleme aşamaları; biçimsel analiz (morphology), sözcüksel analiz (syntax), anlam analizi (semantics), pragmatik analiz (pragmatics) ve söylem analizi (discourse) şeklinde sınıflandırılmıştır. Projemiz, 'Bir Duygu Analiz Yöntemi Olarak Metinden Emoji Tahmini', anlam analizi aracılığıyla metinden duygu çıkarımını içermektedir.

Bilgisayar bilimi ve yapay zeka çalışmalarının bir alt dalı olmasına rağmen, doğal dil işleme çok sayıda bilim dalından da yararlanmaktadır. Günümüzde doğal dil işleme problemlerinin çözümleri için derin öğrenme, makine öğrenmesi, istatistiksel analiz ve kural tabanlı yaklaşımlar hibrit biçimde kullanılmaktadır [4]. Bu nedenle bu konuda uzmanlaşmak isteyenler istatistik, lineer cebir, dilbilim, olasılık, makine öğrenmesi konularında temel düzeyde bilgi sahibi olmalıdır.

Üzerinde çalışılan girdilerin çok çeşitli olması, sabit algoritmalar geliştirilememesi ve söz dizimsel belirsizliklerin söz konusu olması dolayısıyla doğal dil işleme, yapay zekanın en zorlu alanlarından birisidir. Günlük konuşma dilindeki ifadeler insanlar için ne kadar kolay olsa da makineler açısından oldukça karmaşıktır. Örneğin yazılışları aynı fakat anlamları farklı olan kelimelerin makine tarafında yorumlanması sırasında bir belirsizlik oluşmaktadır. Ayrıca belirsizlik, kelime düzeyinde olduğu gibi cümle düzeyinde de olabilmektedir. Araştırmalar, bu sorunları çözmek ve mevcut teknolojileri geliştirmek için yoğun bir şekilde devam etmektedir.

## 1.2 Doğal Dil İşlemenin Uygulama Alanları

**Arama Motoru Optimizasyonu:** Arama motorları, sonuçları sıralarken doğal dil işleme tekniklerinden faydalanır. Bu nedenle, doğal dil işleme tekniklerini etkin bir

şekilde kullanarak aynı işi yapan rakipler arasında öne çıkılarak potansiyel müşterilere daha kolay şekilde ulaşılabilir. Anahtar kelime çıkarımı, öneri sistemler, içerik analizi, sosyal medya analizi, trend analizi gibi alanlarda kullanılır.

**Rutin İşleri Otomatikleştirme:** Sohbet botları (chatbot), doğal dil işleme teknolojisi ile birleştirildiğinde insanlar tarafından gerçekleştirilen birçok rutin görevi otomatikleştirerek çalışanların daha kritik işlere odaklanabilecekleri bir iş ortamı sağlar. Örneğin, bir chatbot gelen talepleri anlar ve bu talepleri kurumsal veritabanındaki ilgili girdilerle eşleştirerek kullanıcılara uygun yanıtı hızlıca sağlar. Bu sayede iş süreçleri daha verimli bir hale getirilir. Müşteri hizmetleri, randevu-rezervasyon sistemleri, bilgi talepleri, iş ilan başvuruları gibi alanlarda kullanılır.

**Büyük Veri Analizi:** Doğal dil işleme teknikleri, büyük veride içerik anlama görevini kolaylaştırır ve belgelerin içeriğini kategorize etmek için kullanılır. Bu sayede, veri analizi daha efektif ve hızlı yapılmış olur. Bu da, büyük veri kütleleri içindeki önemli bilgilerin keşfedilerek daha iyi kararlar verilmesini sağlar. Duygu analizi, metin sınıflandırma, metin özetleme gibi alanlarda kullanılır.

**İçerik Yönetme:** Çok sayıda müşteri yorumu içeren bir veri setinde, doğal dil işleme teknolojisi kullanılarak yorumların içeriği ve amacı analiz edilerek kalite standartlarının korunması ve işletme için olumlu imaj yaratılması sağlanır. Spam filtreleme, içerik sınıflandırma, içerik önerme gibi alanlarda kullanılır.

**Sosyal Medya Analizi:** Sosyal ağlar üzerinden yapılmış yorumlar üzerinde duygu analizi (sentiment analysis) yapılarak hedef kitle hakkında daha iyi bir fikir edinilebilir. Bunun sonucunda, deneme-yanılma yöntemlere başvurmaya gerek kalmaksızın, müşteri memnuniyetini arttırmaya yönelik çalışmalarda başarımlar elde edilir. Duygu analizi, marka izleme, müşteri segmentasyonu gibi alanlarda kullanılır.

### 1.3 Projenin Amacı

Dijitalleşmenin geldiği son durum sebebiyle, birçok sektör değişti ve dönüştü. Elektronik cihaz sayısının dünya nüfusunu geride bıraktığı günümüzde dijital teknolojiye ulaşım sağlayabilen insanlar dünyanın eğilimlerini takip etmektedirler [5]. Dijital teknolojinin bir parçası olma yolunda şirketler de stratejilerini dijital platformlara taşıyarak çalışmalarına buradan devam etmektedirler. Aynı zamanda şirketlerin bu dönüşümü müşterileri de dijital platformlara çekmektedir, çift taraflı bir etki olarak bu döngü büyüyerek gündelik hayatın birçok kısmının internet üzerine taşınmasına yol açmaktadır. Dijital platformlara geçiş yapan bu müşteriler kendi

**Tablo 1.1** Nisan 2022 İtibariyle Bir İnternet Dakikasında Medya Kullanımı

| Karakteristik                    | Dakika Başına Miktar |
|----------------------------------|----------------------|
| Twitter'da Paylaşılan Tweet      | 347.200              |
| Gönderilen Metin                 | 16.000.000           |
| Google Araması                   | 5.900.000            |
| Snapchat'ten Paylaşılan Snap     | 2.430.000            |
| Facebook'ta Paylaşılan İçerik    | 1.700.000            |
| Gönderilen Email                 | 231.400.000          |
| Youtube'a Yüklenen Video Saati   | 500                  |
| Instagram'dan Paylaşılan Gönderi | 66.000               |

içeriklerini de buraya taşımaktadır. Yalnızca içeriklerini taşımakla kalmazlar, aynı zamanda günlük hayatta karşılaştıkları her şeyi internette yorumlayıp değerlendirirler. Bu da internette sürekli olarak bilgi akışı sağlar. Instagram, Twitch ve Twitter gibi çeşitli platformlardan internete veri akışı gerçekleşmektedir. Tablo 1.1'de Nisan 2022 itibariyle 1 internet dakikasındaki medya kullanımı gösterilmektedir.

Her geçen saniye katlanarak artan bu verinin metin içeren kısmını anlamlandırmak için doğal dil işleme yöntemlerinden yararlanılmaktadır. Twitter ise bu metin kaynaklarının en önemlilerinden bir tanesidir. İletişimde verilmek istenen mesajın sadece %7-15'i kelimelerden oluşmaktadır. Bunun haricinde ses tonları ve konseptin %30, jest, mimik ve yüz ifadelerinin ise %55 oranlarında olduğu hesaplanmıştır [6]. Bu nedenle verilmek istenen mesajın önemli bir kısmı duygusal öğelerden oluşur. Metinlerdeki anlam yoğunluğunu artırmak için ise emojiiler kullanılır. Bu metinlerin içerdikleri anlamları tam olarak kavrayabilmek için de duygu analizi yapılmaktadır. Duygu analizi; doğal dil işleme, istatistik, bilgisayar bilimleri gibi alanlardan yöntem ve tekniklerin kullanılması ile görüş sahibinin metin içerisinde belirttiği, duygu, görüş, tutum gibi öznel bilgilerin belirlenmesini amaçlayan güncel bir araştırma alanıdır. Makine öğrenmesi sınıflandırıcıları, aralarında duygu analizinin de yer aldığı, metin madenciliği ve web madenciliğine ilişkin birçok alanda başarıyla uygulanmaktadır [7]. Bu doğrultuda bizim çalışmamızda Twitter verilerinden bir anlam analiz yöntemi olarak duygu çıkarımı yapılmaktadır. Duygu çıkarımı çalışmalarında genellikle nötr, negatif, pozitif anlamlar çıkarmak üzerine yoğunlaşmaktadır fakat bu çalışmada yalnızca bu 3 anlam için sınıflandırma yapmak yerine birçok farklı duygu için sınıflandırma yapılmaktadır.


## 1.4 Veri Seti

Projemizde birçok doğal dil işleme çalışmasında veri seti olarak kullanılan Semeval 2018 Task-2 (Multilingual Emoji Prediction) [8] kullanılmıştır. Semeval'in İngilizce



ve İspanyolca olmak üzere iki farklı veri seti mevcuttur. Bu proje İngilizce veri seti üzerinden yürütülmüştür. "train" ve "test" adlı iki farklı dataset sunulmuştur ve "train" işlemi için kullanılacak veri setinde 368881 adet tweet bulunmaktadır. Bu sayının fazla olması model başarısını olumlu yönde etkileyecek unsurlardan biridir.

Veri setimiz 20 sınıftan oluşmaktadır ve bu sınıfların her biri birer emojiye karşılık gelmektedir. Ancak bu veri setinde Şekil 1.2’de görüldüğü üzere emoji sınıfları homojen dağılım göstermemektedir, ciddi bir dengesizlik söz konusudur. Bu da proje kapsamında aşırı örnekleme (oversampling) kullanılarak çözülmesi gereken sorunlardan birisidir.



Şekil 1.2 Emojilerin Veri Setinde Dağılımı

Veri seti gerçek tweet’lerden oluştuğundan dolayı bilgisayar tarafından anlaşılması ve yorumlanması güçtür. Bu sebeple veri setinde üzerinde bazı normalizasyon işlemleri gerçekleştirilmiştir. Veri setinin işlem görmemiş hali Tablo 1.2’de verilmiştir.

Görüldüğü üzere veriler bir yapay zeka çalışmasına girdi olarak verilmeye uygun yapıda değildir. Kaldı ki bazı tweet’lerin insan gözüyle bakıldığında dahi anlaşılması zordur çünkü bu tweet’ler bir anlam ifade etme gayesiyle paylaşılmamıştır. Bahsedilen durum çalışmanın başarımını olumsuz yönde etkileyen ve geliştirme aşamasında zorluk çıkartan etkenlerden birisidir.

Veri setini temizlerken ilk adım olarak; noktalama işaretlerini, rakamları, rt ifadelerini, "@" ile başlayan kelimeleri, kelimelerin başındaki ve sonundaki gereksiz boşlukları kaldırmayı içeren temizleme işlemleri uygulanmıştır. Bu işlemlerin hepsinde ortak nokta kaldırılan ifadelerin cümlelerin anlamına bir katkı sağlamamasıdır. Bu sebeple

**Tablo 1.2** Veri Setinin Ham Hali

|  |
|--|
| Step out and explore. # @ Ellis Island Cafe  |
| @user @ Cathedral Preparatory School   |
| RuPaul's Drag Race bingo fun. Drag Queens be SEXY! #rupaulsdragrace<br>@user abwyman #la...  |
| Black History like a Mufffffaaaaaka #blacchyna done thru her yugioh trap card like hell ...  |
| @ BJ's Restaurant and Brewhouse  |
| So lovely catching up with my soul sister @user @University of Victoria                      |
| Perfect for this weather #dessert #snowice #snowwhite #lasvegas #summer<br>@ Snow White Cafe |
| Had fun (at @user in New York, NY)   |
| Well Damn @ Oklahoma City, Oklahoma  |
| 'scuse me while I kiss the sky. __ : nikkileekv @ Malibu, California                         |

tweet'ten kaldırılmaları çalışmanın başarısını arttıracaktır. Veri setinin temizlik işlemlerinden sonraki hali Tablo 1.3'de verilmiştir.

**Tablo 1.3** Veri Setinin Temizlenmiş Hali

|  |
|--|
| step out and explore ellis island cafe   |
| cathedral preparatory school   |
| rupauls drag race bingo fun drag queens be sexy rupaulsdragrace abwyman la         |
| black history like a mufffaak blacchyna done thru her yugioh trap card like hell   |
| bjs restaurant and brewhouse   |
| so lovely catching up with my soul siter university of victoria                    |
| perfect for this weather dessert snowice snowwhite lasvegas summer snow white cafe |
| had fun at in new york ny  |
| well damn oklahoma city oklahoma   |
| scuse me while i kiss the sky __ nikkileekv malibu california                      |

Tweet'ler gerçek dünya verisi içerdiğinden doğal dille oluşturulmuş metinlerdir. Gündelik hayatta ses tonu değiştirilerek veya jest, mimik kullanılarak cümlelere anlam katılır fakat yazılı metinde bu mümkün değildir. Bu nedenle bunu sağlamak için kelimelerin orjinal formları dışında harf uzatarak yazılması sık karşılaşılan bir durumdur. Örneğin 'smile' ile 'smilleeeee' sözcüğünün parçalanarak (tokenize) sayısallaştırılmış değerleri veya vektörleştirme (vectorization) işlemi sonrası vektör değerleri birbirlerinden farklı olacaktır fakat bağlama bakıldığında bu kelimeler aynı anlamda kullanılmıştır.

Veri setine bakıldığında karşılaşılan bir diğer durum ise aynı anlama gelen fakat farklı formda yazılmış kelimelerdir. Örneğin 'ny' kısaltması 'new york' ifadesine karşılık gelmektedir, 'hahaha' ile 'hahahahaha' aynı anlamdadır ve 'ough', 'umm' gibi ifadeler gündelik hayatta aynı anlamda kullanılan ünlemlerdir. Bu örnekler genişletilebilir fakat hepsinin ortak noktası bağlama bakıldığında aynı anlama sahip,

farklı şekilde yazılmış kelimeler olmasıdır. Bu durum da vektör ağırlıklarının gereksiz şekilde dağılımına sebep olmaktadır. Bu nedenle bu tür kelimeler tek bir forma dönüştürülmüştür.

Bu sayılan sebeplerden dolayı, veri seti makine öğrenmesi ve derin öğrenme yöntemleriyle yorumlamak için zordur çünkü doğal, gerçek ve filtresiz verilerden oluşmaktadır.

### 2.1 Projeye Olan İhtiyaç

Yazılı metinler tek başına okuyucusuna duygu aktarımı yapamadığı için emoji kullanımı dijital ortamda duyguların ifade edilmesi açısından büyük rol oynar. Emojiler, cümleleri yalnızca olumlu veya olumsuz olarak etiketlemek yerine çok çeşitli duyguları içerebilir. Bu etiketleme işlemi sonucunda her metnin bir sınıfı olur ve bundan sonra gelecek etiketlenmemiş veri, yani emoji kullanılmamış cümle, için bir sınıf tahmini yapılarak metnin anlamının güçlendirilmesi sağlanır. Gerçek piyasada işletmeler, yorumları okuyup anlamlandırarak onları kategorize etmek için çalışanlar bulundurmaktadır. Bu durumun giderilmesi ve duygu çıkarımı işleminin yapay zeka yöntemlerine başvurularak çözülmesi ihtiyacı doğmuştur.

### 2.2 Proje Kapsamı

Projemiz kapsamında sistemden beklenen başarımlar şu şekildedir:

- Kelimelerin sayısallaştırılması (tokenization/vectorization)
- Veri setindeki dengesiz dağılımın yeniden örnekleme teknikleri ile (undersampling/oversampling) giderilmesi
- Çeşitli sınıflandırma (classification) algoritmalarıyla verinin sınıflandırılması
- Sınıflandırılmamış verilere emoji tahmininde bulunulması
- Sistem başarısının gerekli metrikler kullanılarak ölçülmesi
- Başarı oranının daha önceki çalışmalarla kıyaslanması

Bu bölümde uygulamanın geliştirilmesinde izlenebilecek yollar incelenecektir. Uygulamanın geliştirileceği platform, yasal ve ekonomik olarak uygunluğu gibi ayrıntılar anlaşılmaya çalışılacaktır.

### 3.1 Yasal Fizibilite

Kullanılan veri seti Semeval 2018 Task-2 (Multilingual Emoji Prediction), CodaLab üzerinden alınmıştır [8]. Açık kaynaklı olduğu için kullanımında herhangi bir yasal sorunla karşılaşmamaktadır. Ayrıca "train" veri setinin indirilmesi sırasında Twitter geliştirici hesabına (developer account) ihtiyacı olmuştur. Bunun için de gerekli bilgiler doldurularak bir geliştirici hesabı oluşturulmuştur. Proje herhangi bir şekilde yasa ve yönetmelikleri ihlal edecek bir veri tutmamaktadır. Kullanılan bütün kütüphane ve frameworkler açık kaynaklı ve ücretsizdir.

### 3.2 Teknik Fizibilite

#### 3.2.1 Yazılım Fizibilitesi

Projenin geliştirilmesinde Python programlama dili 3.9 versiyonu kullanılmıştır. Geliştirme ortamı olarak en uygun bulunan Google Colab kullanılmıştır ve kodlar bu ortamda derlenmiştir. Yapay zeka modellerinin geliştirilmesinde kullanılan Python kütüphaneleri de tamamen ücretsiz ve açık kaynaklıdır. Açık kaynaklı kütüphanelerin kullanımı sistemin gerçekleşmesine pozitif etki etmiştir.


#### 3.2.2 Donanım Fizibilitesi

Proje Windows 10 ve 11 işletim sistemleri üzerinde gerçekleştirilmektedir. Projenin geliştirilmesi Google Colab üzerinden olduğu için bilgisayarın CPU ve GPU'sunun yanında Colab'in sağladığı TPU ve GPU desteği kullanılmıştır. Colab, bu açıdan Jupyter Notebook'a kıyasla daha avantajlıdır. Büyük ölçekli bir veriyle uğraştığımız için bu

önemli bir noktadır ve çalışma süresinin kısalmasına yardımcı olmaktadır. Ayrıca Google Colab, RAM ve depolama alanı desteği de sunmaktadır.

### 3.3 İş Gücü ve Zaman Fizibilitesi

2 kişi 2 buçuk ay sürede gerçekleşmiştir. 3.1’de görevlerin tamamlanması için gereken ve harcanan zaman gösterilmiştir.



Şekil 3.1 İş / Zaman Çizelgesi

### 3.4 Ekonomik Fizibilite

Geliştirme ortamı olarak Google Colab’ın ücretsiz sürümü kullanılmaktadır. Yazılım aracı olarak kullanılan derin örğenme ve makine öğrenmesi yöntemleri de ücretsizdir. Veri seti olarak kullanılan SemeEval Task-2’de açık kaynaklı ve ücretsizdir.

Donanım olarak HP Pavilion 15 ve Lenovo IdeaPad L340 markalı kişisel bilgisayarlarımız kullanılmıştır. Bu bilgisayarlar sistem gereksinimlerini karşılamaktadır. Detaylı maliyet tablosu Tablo 3.1’de görüldüğü gibidir.

Tablo 3.1 Ekonomik Fizibilite Tablosu

| Araç                  | Adet | Fiyat    | Maliyet         |
|-----------------------|------|----------|-----------------|
| Lenovo İdeaPad L340   | 1    | 30000 TL | 30000 TL        |
| HP Pavilion 15        | 1    | 20000 TL | 20000 TL        |
| Google Colab          | 0    | 0 TL     | 0 TL            |
| <b>Toplam Maliyet</b> |      |          | <b>50000 TL</b> |

### 4.1 Gereksinim Analizi

Projemizde makine öğrenmesi (machine learning) ve derin öğrenme (deep learning) yöntemlerinin uygulanmasını mümkün kılacak Pandas, TensorFlow, NumPy, Seaborn, Sklearn, Pytorch gibi kütüphaneler kullanılmaktadır. Bu kütüphanelerin import edilip kullanılabilmesi için Jupyter Notebook, Anaconda Navigator veya Google Colab gibi geliştirme ortamlarına ihtiyaç duyulmaktadır. Bu ortamlar arasından büyük boyutlu veri üzerinde en efektif çalışma ortamını sağlaması ve ücretsiz olması gerekçeleriyle Google Colab üzerinden çalışılması tercih edilmiştir. Python kodlama dili kullanılmıştır.

Projemiz input olarak gerçek tweet'lere ihtiyaç duymaktadır. Bu ihtiyaç da Twitter'dan çekilmiş ve emoji'leri etiketlenmiş halde bulunan Semeval Task-2 veri setiyle karşılanmaktadır.

### 4.2 Hedefler

Çalışmamızın ana hedefi eğitilen model ile daha önce sınıflandırılmamış metinlere en uygun emoji'yi bularak anlam analizi yapmaktır. Bu sayede duygu sınıflandırılması yapılmamış metinlerin anlamlarını en doğru şekilde tahmin ederek duygu sınıflandırması yapılır. Bu doğrultuda literatürdeki makine öğrenmesi yöntemleriyle modeller oluşturularak tahminler yapılmış ve başarı oranları hesaplanmıştır. Elde edilen başarı ölçümleri karşılaştırılarak en efektif model tespit edilmeye çalışılmıştır. Ayrıca birkaç veri normalizasyon tekniği tüm modellere ayrı ayrı uygulanarak tekniklerin etkileri görülmeye çalışılmıştır.

### 4.3 Performans Metrikleri


Farklı makine öğrenmesi ve derin öğrenme algoritmaları kullanılarak tahmin edilen etiketler test veri setiyle karşılaştırılarak başarı hesaplanır. Bunun için doğruluk puanı (accuracy score), F-1 puanı (F-1 score), karışıklık matrisi (confusion matrix) vb. başarı ölçüm metrikleri kullanılmaktadır. Veri setinde etiketlerin dağılımının dengeli olmamasından dolayı doğruluk puanı yöntemi yanıltıcı bir değer verebilmektedir. Bunun yerine F-1 puanı ve karışıklık matrisi kullanılarak her bir sınıfın yüzde kaç doğruluk oranına sahip olduğu bulunabilir.

Projenin literatürdeki örneklerine bakıldığında, veri setinin çarpık dağılımı nedeniyle sistemlerin F-1 puanı makro ortalama (F-1 score macro avg.) göre değerlendirildiği görülmüştür. Bu nedenle modellerimizin başarı kıyaslamaları makro ortalama üzerinden yapılmıştır.



### 5.1 Yazılım Tasarımı

Yazılım tasarım aşamaları Şekil 5.1'deki akış diyagramında gösterilen adımları kapsamaktadır. İlerleyen başlıklarda bu adımlar detaylı bir şekilde açıklanacaktır.



Şekil 5.1 Yazılım Tasarımı Akış Diyagramı

### 5.1.1 Ön İşleme

Elimizde bulunan Semeval Task-2 veri seti gerçek dünyadan alınmış bir veri setidir. İnsan dili, yapısı gereği karmaşık bir yapıya sahiptir. Bilgisayarların bu dili algılayabilmesi ve işleyebilmesi için bu verilerin düzenlenmesi gerekir [9]. Datasetimizde yanlış yazımlar, kısaltmalar, harf tekrarları gibi birçok istenmeyen özellik bulunmaktadır. Bu nedenle veriyi eğitmeye başlamadan önce kapsamlı bir normalizasyon işleminden geçirilmesi gerekmektedir. Noktalama işaretleri, stopword'ler, url karakterler, HTML karakterleri, fazla boşluklar kaldırılmıştır. Verinin tamamı küçük harfe çevrilmiştir. Tweetlerde bulunan '@' ve '#' işaretleri kaldırılmıştır. Harf tekrarı yapılmış kelimelerdeki fazla harfler silinmiştir. Bu işlemlerle veri düzenlenerek standart bir hale getirilmiştir.

### 5.1.2 Veri Sayısallaştırma

Veriyi modelde kullanılabilir hale getirmek için sayısallaştırmak gerekmektedir. Bunun için de tokenizasyon ve vektörleştirme olmak üzere iki farklı yol izlenebilir. LSTM, CRF, RNN gibi geleneksel modeller tokenizasyonu kullanırken; BERT gibi modern modellerde ise vektörizasyon kullanılmaktadır.

**Tokenizasyon:** Metin verisi boşluklara veya belirlenene ayracın bulunduğu yerlere göre daha küçük parçalara, yani token'lara ayrılır. Bu parçalama işlemi genellikle kelime seviyesinde yapılır. Daha sonra her token için birer token numarası (token id) atanır.

**Vektörleştirme:** Metinleri sayısal vektörlere dönüştürme işlemidir. 'Word embeddings' kullanılır. One Hot Encoding, TF-IDF, Word2Vec, FastText, yöntemleri sıklıkla kullanılan Word Embedding yöntemleridir [10].

### 5.1.3 Veri Örneklerinin Boyutlarının Eşitlenmesi

Sayısallaştırılmış verinin sabit ve tek bir uzunluğa getirilmesi işlemidir (padding). Bu proje kapsamında düşünüldüğünde, en uzun tweetin kelime sayısı hesaplanır ve diğer tweetler de aynı boyuta getirilmek üzere başına veya sonuna 0'lar eklenerek doldurulur.

### 5.1.4 Yeniden Örnekleme

Dengesiz veri seti, sınıflandırma problemlerinde görülür ve sınıf dağılımlarının birbirine yakın olmadığı durumlarda ortaya çıkar. Problem çoğunluğa sahip sınıfın azınlık sınıfı domine etmesinden kaynaklanır. Oluşturulan model çoğunluğa sahip

sınıfa yakınlık gösterir, bu da azınlık sınıfın kötü sınıflandırılmasına sebep olur [11]. Azınlık sınıfa yeni örnekler ekleyerek veya çoğunluk sınıftan örnek eksilterek yeniden örnekleme (resampling) uygulanabilir. Kullanılan modellerde Rastgele Aşırı Örnekleme (ROS) ve Sentezlenmiş Azınlık Aşırı-Örnekleme (SMOTE) metodları kullanılmıştır.

**Rastgele Aşırı Örnekleme (ROS):** ROS yöntemi ile azınlık sınıfa ait örneklerin sayısı rastgele seçilen örneklerin tekrarlanması ile artırılır. Azınlık sınıfa ait bir örnek seçilir ve bu örnek veri setine eklenir. Bu işlem, belli bir sayıda sentetik örnek üretilene kadar tekrarlanır.


**Sentezlenmiş Azınlık Aşırı Örnekleme (SMOTE):** SMOTE yöntemi ile azınlık sınıfı daha iyi temsil etmek için sentetik örnekler oluşturulur. Azınlık sınıfa ait bir örnek seçilir ve bu örneğe en yakın komşular belirlenir. Seçilen örnek ile bir veya daha fazla komşusu arasında rastgele bir nokta seçilerek azınlık sınıfa ait yeni bir sentetik örnek eklenir. Bu işlem, belli bir sayıda sentetik örnek üretilene kadar tekrarlanır.

#### 5.1.5 Modelleme


Projemiz kapsamında geleneksel ve modern modellemeler kullanılmıştır. Bunlar: LSTM, Bidirectional LSTM ve BERT modelleridir. LSTM ve BLSTM modellerinde Glove, Word2Vec ve Keras olmak üzere 3 farklı gömme modeli kullanılmıştır. BERT'te ise doğrudan Word2Vec veya GloVe gibi geleneksel kelime düzeyi gömme modelleri kullanılmaz. Bu modellerin yerine belirteç gömme (token embedding), segment gömme (segment embedding) ve konum gömme (position embedding) modellerinin bir kombinasyonu kullanılır. ROS ve SMOTE olmak üzere 2 farklı aşırı örnekleme tekniği kullanılarak çeşitli sonuçlar elde edilmiştir.

**LSTM:** Uzun kısa süreli bellek (Long Short-Term Memory) derin öğrenme alanında kullanılan yapay bir yinelemeli sinir ağı (recurrent neural network) mimarisidir [12]. RNN'in kısa vadeli bir hafıza olmasından dolayı LSTM gibi çeşitli ağlar önerilmiştir. LSTM, bilgileri daha iyi depolayarak, standart RNN'in kısa vadeli bellek problemini ortadan kaldırmak için tasarlanmıştır [13]. LSTM'ler daha çok girdilerle çıktılarının birlikte ve veri kaybolmadan çalışmasını sağlayan yöntemdir.

Tüm tekrarlayan sinir ağları Şekil 5.2'deki gibi tekrar eden zincir formundaki hücrelerden oluşur. Hücre olarak adlandırılan şekiller ağın her bir zaman adımındır. Standart bir RNN, tek bir 'tanh' katmanı gibi basit bir yinelenen modüle sahiptir. LSTM'de de Şekil 5.3'teki gibi tekrar eden bir yapı vardır ancak bir sonraki parça daha farklı bir yapıya sahiptir.



Şekil 5.2 Standart RNN [14]



Şekil 5.3 LSTM [14]


Yinelemeli sinir ağlarında (RNN), görülen bilgiler unutulabilir fakat LSTM yalnızca gelen girdi önemsizse unuttur, gelen girdi önemliyse bir sonraki aşamaya aktarır. Bu karar mekanizmasını Gate ve Cell State yardımıyla sağlar.

- **Unutma Kapısı (Forget Gate):** Hangi bilginin tutulacağına veya unutulacağına karar verir. Unutmak için girdinin ağırlığına 0 verilir. Bir önceki gizli katmandan gelen bilgiler ve güncel bilgiler sigmoid fonksiyonundan geçer. 0'a ne kadar yakınsa o kadar unutulacak, 1'e ne kadar yakınsa o kadar tutulacak anlamına gelir.
- **Girdi Kapısı (Input Gate):** Hücre durumunu güncellemek için kullanılır. Unutma kapısında olduğu gibi sigmoid fonksiyonu uygulanarak hangi bilginn tutulacağına karar verir. Daha sonra ağı düzenlemek için tanh fonksiyonu yardımıyla -1,1 arasına indirgenir ve çıkan iki sonuç çarpılır.
- **Hücre Durumu (Cell State):** Hücre içerisindeki en önemli görevi, bilgiyi taşımaktır. Taşınması gereken verileri alır ve hücre sonuna, oradan da diğer hücrelere taşır. Yani ağ üzerinde veri akışını Cell State yardımıyla sağlarız. İlk olarak Forget Gate'ten (Unutma Kapısı) gelen sonuç ile bir önceki katmanın sonucu çarpılır. Daha sonra Input Gate'ten (Girdi Kapısı) gelen değer ile toplanır.

- **Çıktı Kapısı (Output Gate):** Bir sonraki katmana gönderilecek değere karar verir. Bu değer, tahmin için kullanılır. Öncelikle bir önceki değer ile şu anki girdi sigmoid fonksiyonundan geçer. Hücre durumundan gelen değer tanh fonksiyonundan geçtikten sonra iki değer çarpılır ve bir sonraki katmana “Bir önceki değer” olarak gider. Hücre durumu ilerler [14].

**BLSTM:** Standart LSTM'den farklı olarak İki Yönlü Uzun Kısa Süreli Bellekte (Bidirectional Long Short Term Memory), girdi her iki yönde de akar ve her iki taraftan gelen bilgileri kullanma yeteneğine sahiptir. Girdilerin biri ilerden geriye diğeri geriden ileriye doğru yürütülür. BLSTM yaklaşımını yönlü yaklaşımdan ayıran en büyük şey BLSTM'de ilerden gelen bilgilerin korunabiliyor olmasıdır [15].

BLSTM, veri akışı yönünü tersine çeviren bir LSTM katmanını daha ekler. Ardından Şekil 5.4'teki gibi her iki katmandan gelen LSTM çıktıları üzerinde ortalama, çarpma, bölme gibi çeşitli işlemler uygulanarak çıktılar birleştirilir.




Şekil 5.4 BLSTM [16]

**BERT:** Dönüştürücülerden İki Yönlü Kodlayıcı Temsilleri (Bidirectional Encoder Representations from Transformers - BERT), doğal dil işleme ön eğitimi için Google'ın sinir ağı tabanlı tekniğidir. Bu teknik aracılığıyla, Google kullanıcıların arama sorgularını daha iyi analiz ederek kullanıcılara daha doğru sonuçlarla hizmet vermektedir.

BERT, transformatör mimarisine dayalıdır ve diğer modellerden farklı olarak cümleyi hem soldan sağa hem de sağdan sola olarak değerlendirmektedir. Bu sayede anlamı ve kelimelerin birbiriyle olan ilişkileri daha iyi tespit edilmektedir [16]. Metin içerisindeki bir kelimenin bağlamını kendisinden önce ve sonra gelen kelimelere bakarak öğrenebilmektedir.


BERT, çift yönlü olmasının yanı sıra Maskeli Dil Modelleme (Masked Language Modeling - MLM) ve Sonraki Cümle Tahmini (Next Sentence Prediction - NSP)

adı verilen iki teknikle eğitilmiştir. MLM ve NSP teknikleri kullanılarak bu kadar büyük bir veri setiyle transformer modelini eğitmek oldukça masraflıdır. Bu nedenle hazır eğitilmiş modeller Şekil 5.5'teki gibi ince ayarlama (fine-tuning) denilen teknik kullanılarak yeni problemlerin çözümünde kullanılır.



Şekil 5.5 BERT [16]

**BERT Gömme Modeli:** BERT modelinde embedding olarak belirteç gömme (token embedding), segment gömme (segment embedding) ve pozisyon gömme (position embedding) modellerinin bir kombinasyonu kullanılır. Şekil 5.6'da final girdi belirtecini (input token) oluşturmak için gömmelerin (embeddings) nasıl bir araya getirildiği gösterilmektedir.



Şekil 5.6 BERT Girdi Gösterimi [17]

- **Belirteç Gömme (Token Embedding):** Kodlayıcıda belirli bir anlam taşıyan bazı önemli belirteçler (token) bulunmaktadır. CLS ; sınıflandırmayı temsil etmektedir, girdi metninin başlangıcında kullanılır. SEP , iki farklı metin öbeğini birleştirmede kullanılır.
- **Segment Gömme (Segment Embedding):** Segment gömme, çift girişli (paired input) görevlerde kullanılan bir gömme katmanıdır. BERT modelinde, iki farklı metin öbeği birleştirilirken segment gömme işaretleri kullanılır.

- **Pozisyon Gömme (Position Embedding):** Çift yönlü mekanizmanın kullanıldığı transformer tabanlı bir model olan BERT, kelimenin dizilimini (pozisyonunu) dikkate alır. Her kelime bulunduğu sıraya bağlı olarak bir vektörle gösterilir [17].

**Word2Vec:** Word2Vec, kelime gömme (word embedding) yöntemlerinden biridir. Kelimeleri vektör uzayında ifade etmeye çalışan denetimsiz öğrenme(unsupervised) ve tahmin temelli (prediction-based) bir modeldir [18]. Word2Vec'in iki çeşit alt yöntemi vardır: Sürekli Kelime Torbası (Continuous Bag-of-Words - CBOW) ve Skip-gram. Küçük veri setlerinde CBOW daha iyi çalışırken, büyük veri setlerinde Skip-gram daha iyi sonuç vermektedir.

- **Sürekli Kelime Torbası (CBOW):** CBOW modelinde, hedef kelimeyi tahmin etmek için hedef kelimenin önceki veya sonraki kelimeler olacak şekilde metindeki bağlam kelimeler kullanılır. Model, bağlam kelimelerin ortalaması aracılığıyla hedef kelimeyi tahmin eder.
- **Skip-gram:** Skip-gram modeli, CBOW modelinden farklı olarak hedef kelime üzerinde bağlam kelimeleri tahmin etmeye çalışır.

Modellerimizde gensim kütüphanesi kullanılarak Google tarafından oluşturulmuş geniş bir kelime gömme modeli olan "word2vec-google-news-300" kullanılmaktadır. Bu model Google News veri seti üzerinde eğitilmiştir ve kelimeleri 300 boyutlu vektörlerle temsil eder. Gömme modelinde yaklaşık olarak 3 milyon kelime bulunmaktadır.

**GloVe (Global Vectors for Word Representation):** GloVe, kelime temsilleri için kullanılan bir dağıtımsal kelime gömme (embedding) yöntemidir. GloVe modeli, olasılık istatistiklerinden yararlanarak yeni bir objektif fonksiyon oluşturur [19]. Stanford tarafından geliştirilmiş denetimsiz (unsupervised) bir öğrenme algoritmasıdır [20].

Modellerimizde GloVe modelinin önceden eğitilmiş bir versiyonu olan ve sosyal medya verileri üzerinde eğitilmiş "glove.twitter.27B.200d" modeli kullanılmaktadır. 27 milyar tweet üzerinden eğitilerek her kelime 200 boyutlu bir vektör temsili üzerinden gösterilmiştir.

Bu bölümde modellerin özellikleri ve eğitimlerine dair bilgi verilecektir.

### 6.1 Modellerin Özellikleri

Ham veride yaklaşık 350 bin tweet bulunmaktadır, bu tweetlerin bir kısmı test ve doğrulama için ayrılmıştır ve sonuçta elimizde yaklaşık 250 bin tweetlik bir eğitim verisi bulunmaktadır. Veri setinde toplam 20 adet emoji bulunmaktadır. LSTM, BLSTM ve BERT modelleri kullanılarak tahmin yapılmasının ardından mor kalp, kırmızı kalp, ikili kalp gibi bazı emojiğin ifade ettikleri anlam bakımından birbirine çok benzediği bu nedenle tahmin aşamasında sıkça karıştırıldığı görülmüştür. Bunun üzerine 20 emoji kullanılarak eğitilen modellerin yanı sıra bazı emojiğin gruplandırılmış ve 14 emoji kullanılarak eğitilen model ile başarının artırılması hedeflenmiştir.

Eğitilen modellerde 0 numaralı emojiğin tahminlerde çok baskın olduğu görülmüştür. Bu nedenle başarının artırılması hedeflenerek uygulanan bir diğer değişiklik, İki Aşamalı Sınıflandırma (Two Stage Classification) uygulanmasıdır. Bu yöntemde sınıflandırma iki adımda tamamlanmıştır. İlk adımda girdi cümleğin 0 numaralı emojiğe mi yoksa diğer 19 emojiğden herhangi birine mi ait olduğuna karar verilir. İkinci adımda ise cümle diğer 19 emojiğden birine ait ise hangi emojiğe ait olduğuna karar verilir.

İlerleyen başlıklarda bu modellerin başarımları sonuçları açıklanmaktadır.

### 6.2 Modellerin Eğitilmesi

LSTM ve BLSTM modellerinin eğitilmesinde Google Colab'ın sunduğu CPU kullanılmıştır. BERT modelinde ise çok fazla işlem gücü gerektiğinden Google Colab'ın sunduğu GPU donanım hızlandırıcısı kullanılmıştır.

Veri setinin %10'u test, %90'ı eğitim için ayrılmıştır. Modelin eğitimi sırasında



performansını deęerlendirmek iin kullanılan doęrulama veri kmesi iinse %90'lık verinin %20 si doęrulama verisi olarak ayrılmıřtır. Model her eęitim dngs (epoch) sonunda doęrulama veri kmesindeki performansını deęerlendirir ve doęrulama metriklerini hesaplar. Bu uygulama ařırı uydurma (overfitting) durumunu tespit etmek bakımından nemlidir. Doęrulama veri kmesi ile, her bir eęitim dngs sonunda modelin kaybını (los) ve metriklerini hesaplayarak eęitim srecini erken durdurma (early stopping) gibi callback fonksiyonları kullanılmıřtır.

EarlyStopping sınıfı, eęitim sırasında modelin belirli bir metrięinin geliřimini izler ve bir iyileřme olmadıęında eęitimi durdurur. Bu yntem ařırı uydurmayı (overfitting) nlemeye yardımcı olur ve en iyi modeli semek iin kullanılır. Modellerimizde kullanılan early stop fonksiyonu, doęrulama kaybı (vall\_loss) metrięinin geliřimini izler.

# 7

## Deneyisel Sonuçlar

Bu bölümde projenin deneyisel sonuçları açıklanmaktadır.

### 7.1 Eğitim, Doğrulama ve Test Ayrımı

Yapılan deneyisel çalışmalarda SemEval Task-2 açık kaynak ortamından temin edilen toplamda 346.748 tweetten oluşan bir veri seti kullanılmıştır. Veri setinin %10'u olan 34.674 tweet test için ayrılmıştır. Geri kalan 312.074 tweet'in %80'i olan 249.660 tweet eğitim, %20'si olan 62.414 tweet doğrulama için ayrılarak kullanılmıştır.

### 7.2 Model Sonuçları

LSTM, BLSTM, BERT modelleri ile; Word2Vec, GloVe, Keras Embedding olmak üzere 3 ayrı gömme modeli uygulanmıştır. Her bir model için aşırı örnekleme uygulanarak ve uygulanmayarak ayrı sonuçlar elde edilmiştir. Aşırı örnekleme için ise ROS ve SMOTE olmak üzere iki farklı yöntem kullanılmıştır. Tüm bu modellerin başarımları f-1 puanı makro ortalama (f-1 score macro avg) dikkate alınarak kıyaslanmıştır.

#### 7.2.1 LSTM

**Tablo 7.1** LSTM Modelleri için F-1 Score Sonuçları

|                           | Word2Vec | GloVe | Keras |
|---------------------------|----------|-------|-------|
| ROS ile Aşırı Örnekleme   | 0.21     | 0.21  | 0.20  |
| SMOTE ile Aşırı Örnekleme | 0.18     | 0.20  | 0.17  |
| Aşırı Örneklemesiz        | 0.20     | 0.22  | 0.19  |

Tablo 7.1'e bakıldığında LSTM modellerinde en yüksek başarımların GloVe gömme modeli kullanılarak aşırı örnekleme yapılmadığı durumda 0.22 olarak elde edildiğini görmekteyiz.

### 7.2.2 BLSTM

**Tablo 7.2** BLSTM Modelleri için F-1 Score Sonuçları

|                           | Word2Vec | GloVe | Keras |
|---------------------------|----------|-------|-------|
| ROS ile Aşırı Örnekleme   | 0.26     | 0.21  | 0.19  |
| SMOTE ile Aşırı Örnekleme | 0.23     | 0.21  | 0.18  |
| Aşırı Örnekleme           | 0.27     | 0.29  | 0.19  |

Tablo 7.2'ye bakıldığında BLSTM modellerinde en yüksek başarımların GloVe gömme modeli kullanılarak aşırı örnekleme yapılmadığı durumda 0.29 olarak elde edildiğini görmekteyiz.

### 7.2.3 BERT

BERT modelinde embedding olarak belirteç gömme (token embedding), segment gömme (segment embedding) ve pozisyon gömme (position embedding) modellerinin bir kombinasyonu kullanılır. Bu nedenle modele diğer Word2Vec ve GloVe gömme modelleri uygulanmamıştır.

**Tablo 7.3** BERT Modelleri için F-1 Score Sonuçları

|                         | Combined Embedding |
|-------------------------|--------------------|
| ROS ile Aşırı Örnekleme | 0.26               |
| Aşırı Örnekleme         | 0.25               |

Model sonuçlarında, tahmin edilen emojielerde 0 numaralı emojiye çok baskın olduğu görülmüştür. Bu nedenle İki Aşamalı Sınıflandırma (Two Stage Classification) uygulanarak ilk adımda girdi cümlelerin 0 numaralı emojiye mi yoksa diğer 19 emojiye herhangi birine mi ait olduğuna; ikinci adımda ise cümle diğer 19 emojiye birine ait ise hangi emojiye ait olduğuna karar verilir.

### 7.2.4 İki Aşamalı Sınıflandırma

Uygulanan üç modelin (LSTM, BLSTM, BERT) her birinde en yüksek başarıya sahip olan versiyon sarı ile belirtilmiştir. Bu modeller, GloVe gömme modeli ile aşırı örnekleme olmadan LSTM, GloVe gömme modeli ile aşırı örnekleme olmadan BLSTM ve Random Oversampling ile BERT'tir. İki aşamalı sınıflandırma uygulamak için bu modeller seçilmiştir. Fakat ROS uygulanan BERT modelinde 0 numaralı sınıf için bariz bir yığılma görülmemektedir. Bu nedenle bu model yerine aşırı örnekleme uygulanmayan BERT modeli üzerinde iki aşamalı sınıflandırma denenmiştir. İki aşamalı sınıflandırma uygulanarak elde edilen başarımların ölçümleri Tablo 7.4'te yer almaktadır.

**Tablo 7.4** İki Aşamalı Sınıflandırma için F-1 Score Sonuçları

|   | İki Aşamalı Sınıflandırma |
|---|---------------------------|
| LSTM (GloVe Gömme Modeli & Aşırı Örneklemesiz)  | 0.23                      |
| BLSTM (GloVe Gömme Modeli & Aşırı Örneklemesiz) | 0.27                      |
| BERT  | 0.27                      |

## 8 Performans Analizi


Bu bölümde yüksek başarımla elde edilen modellerin performans analizleri yapılacaktır.

### 8.1 LSTM

LSTM modellerinden en yüksek başarıma aşırı örnekleme yapılmadan GloVe gömme modelinin kullanıldığı model ulaşmıştır. Bu modelin makro ortalama f-1 doğruluk puanı 0.22'dir. Modelde her bir class için elde edilmiş f-1 puanı Şekil 8.1'de görülmektedir. Modelin karışıklık matrisi (confusion matrix) Şekil 8.2'de görülmektedir.

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.34      | 0.71   | 0.46     | 7385    |
| 1            | 0.29      | 0.25   | 0.27     | 3714    |
| 2            | 0.39      | 0.58   | 0.47     | 3734    |
| 3            | 0.27      | 0.02   | 0.04     | 1790    |
| 4            | 0.39      | 0.56   | 0.46     | 1802    |
| 5            | 0.18      | 0.04   | 0.06     | 1644    |
| 6            | 0.20      | 0.09   | 0.13     | 1534    |
| 7            | 0.25      | 0.20   | 0.22     | 1231    |
| 8            | 0.35      | 0.04   | 0.07     | 1153    |
| 9            | 0.23      | 0.04   | 0.07     | 1156    |
| 10           | 0.24      | 0.19   | 0.21     | 1129    |
| 11           | 0.54      | 0.50   | 0.52     | 1029    |
| 12           | 0.33      | 0.50   | 0.40     | 952     |
| 13           | 0.49      | 0.03   | 0.06     | 871     |
| 14           | 0.20      | 0.02   | 0.03     | 1030    |
| 15           | 0.31      | 0.15   | 0.20     | 967     |
| 16           | 0.50      | 0.01   | 0.01     | 940     |
| 17           | 0.54      | 0.70   | 0.61     | 855     |
| 18           | 0.24      | 0.10   | 0.14     | 902     |
| 19           | 0.21      | 0.00   | 0.01     | 857     |
| micro avg    | 0.35      | 0.35   | 0.35     | 34675   |
| macro avg    | 0.32      | 0.24   | 0.22     | 34675   |
| weighted avg | 0.32      | 0.35   | 0.28     | 34675   |
| samples avg  | 0.35      | 0.35   | 0.35     | 34675   |

Şekil 8.1 LSTM F-1 Skor Sonuçları




Şekil 8.2 LSTM Confusion Matrix

## 8.2 BLSTM

BLSTM modellerinden en yüksek başarıma aşırı örnekleme yapılmadan GloVe gömme modelinin kullanıldığı model ulaşmıştır. Bu modelin makro ortalama f-1 doğruluk puanı 0.29'dur. Aynı zamanda bu model tüm modellerin arasında en yüksek başarıya sahip modeldir. Modelde her bir class için elde edilmiş f-1 puanı Şekil 8.3'de görülmektedir. Modelin karışıklık matrisi (confusion matrix) Şekil 8.4'de görülmektedir.

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.35      | 0.72   | 0.52     | 7477    |
| 1            | 0.29      | 0.29   | 0.34     | 3634    |
| 2            | 0.39      | 0.56   | 0.51     | 3600    |
| 3            | 0.25      | 0.02   | 0.08     | 1725    |
| 4            | 0.46      | 0.50   | 0.53     | 1882    |
| 5            | 0.20      | 0.06   | 0.14     | 1748    |
| 6            | 0.20      | 0.08   | 0.16     | 1564    |
| 7            | 0.32      | 0.19   | 0.29     | 1285    |
| 8            | 0.30      | 0.04   | 0.12     | 1105    |
| 9            | 0.19      | 0.03   | 0.10     | 1136    |
| 10           | 0.24      | 0.19   | 0.26     | 1195    |
| 11           | 0.52      | 0.53   | 0.57     | 1073    |
| 12           | 0.30      | 0.52   | 0.43     | 889     |
| 13           | 0.64      | 0.03   | 0.10     | 838     |
| 14           | 0.12      | 0.03   | 0.05     | 927     |
| 15           | 0.31      | 0.17   | 0.27     | 973     |
| 16           | 0.15      | 0.02   | 0.08     | 941     |
| 17           | 0.56      | 0.75   | 0.69     | 853     |
| 18           | 0.28      | 0.09   | 0.19     | 981     |
| 19           | 0.23      | 0.01   | 0.07     | 849     |
| micro avg    | 0.35      | 0.35   | 0.35     | 34675   |
| macro avg    | 0.31      | 0.24   | 0.29     | 34675   |
| weighted avg | 0.32      | 0.35   | 0.29     | 34675   |
| samples avg  | 0.35      | 0.35   | 0.35     | 34675   |

Şekil 8.3 BLSTM F-1 Skor Sonuçları



Şekil 8.4 BLSTM Confusion Matrix




### 8.3 BERT

BERT modellerinde en yüksek başarıma ROS uygulanan model ulaşmıştır. Bu modelin makro ortalama f-1 doğruluk puanı 0.26'dır. Modelde her bir class için elde edilmiş f-1 puanı Şekil 8.5'de görülmektedir. Modelin karışıklık matrisi (confusion matrix) Şekil 8.6'da görülmektedir.

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.45      | 0.23   | 0.31     | 7385    |
| 1            | 0.26      | 0.29   | 0.28     | 3714    |
| 2            | 0.46      | 0.45   | 0.45     | 3734    |
| 3            | 0.14      | 0.24   | 0.18     | 1790    |
| 4            | 0.44      | 0.50   | 0.47     | 1802    |
| 5            | 0.12      | 0.18   | 0.14     | 1644    |
| 6            | 0.13      | 0.20   | 0.16     | 1534    |
| 7            | 0.20      | 0.23   | 0.21     | 1231    |
| 8            | 0.14      | 0.14   | 0.14     | 1153    |
| 9            | 0.13      | 0.15   | 0.14     | 1156    |
| 10           | 0.24      | 0.25   | 0.24     | 1129    |
| 11           | 0.52      | 0.60   | 0.56     | 1029    |
| 12           | 0.36      | 0.42   | 0.39     | 952     |
| 13           | 0.13      | 0.13   | 0.13     | 871     |
| 14           | 0.13      | 0.09   | 0.11     | 1030    |
| 15           | 0.24      | 0.22   | 0.23     | 967     |
| 16           | 0.11      | 0.09   | 0.10     | 940     |
| 17           | 0.53      | 0.70   | 0.60     | 855     |
| 18           | 0.22      | 0.22   | 0.22     | 902     |
| 19           | 0.08      | 0.07   | 0.07     | 857     |
| accuracy     |           |        | 0.28     | 34675   |
| macro avg    | 0.25      | 0.27   | 0.26     | 34675   |
| weighted avg | 0.30      | 0.28   | 0.28     | 34675   |

Şekil 8.5 BERT F-1 Skor Sonuçları



Şekil 8.6 BERT Confusion Matrix

## 8.4 İki Aşamalı Sınıflandırma (BERT)

Şekil 8.1 ve Şekil 8.3'teki karışıklık matrislerine (confusion matrix) bakıldığında tahmin edilen etiketlerde 0 numaralı sınıfın baskın olduğu görülmektedir. Bu yığılmayı dağıtmak amacıyla iki aşamalı sınıflandırma uygulanmıştır.


İki aşamalı sınıflandırma modelleri arasında aşırı örnekleme yapılmadan GloVe gömme modelinin kullanıldığı BLSTM modeli ve aşırı örnekleme yapılmayan BERT modeli 0.27 başarımla en yüksek başarıma ulaşmışlardır. Bu başlıkta aşırı örnekleme yapılmamış BERT modeli incelenecektir.

Modelde her bir class için elde edilmiş f-1 puanı Şekil 8.7'de görülmektedir. Aşırı örnekleme yapılmadan uygulanan tek adımlı BERT modelinin karışıklık matrisi (confusion matrix) Şekil 8.8'de, iki adım ile uygulanan modelin karışıklık matrisi ise Şekil 8.9'da görülmektedir.


|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.45      | 0.38   | 0.41     | 7426    |
| 1            | 0.26      | 0.44   | 0.32     | 3670    |
| 2            | 0.41      | 0.60   | 0.49     | 3640    |
| 3            | 0.18      | 0.20   | 0.19     | 1787    |
| 4            | 0.49      | 0.53   | 0.51     | 1819    |
| 5            | 0.15      | 0.16   | 0.15     | 1660    |
| 6            | 0.17      | 0.14   | 0.15     | 1548    |
| 7            | 0.26      | 0.27   | 0.26     | 1238    |
| 8            | 0.22      | 0.12   | 0.16     | 1128    |
| 9            | 0.18      | 0.16   | 0.17     | 1144    |
| 10           | 0.28      | 0.32   | 0.29     | 1171    |
| 11           | 0.55      | 0.61   | 0.58     | 1054    |
| 12           | 0.35      | 0.51   | 0.42     | 933     |
| 13           | 0.35      | 0.05   | 0.08     | 882     |
| 14           | 0.14      | 0.08   | 0.10     | 954     |
| 15           | 0.27      | 0.21   | 0.23     | 974     |
| 16           | 0.14      | 0.02   | 0.04     | 934     |
| 17           | 0.57      | 0.73   | 0.64     | 886     |
| 18           | 0.27      | 0.13   | 0.18     | 959     |
| 19           | 0.12      | 0.01   | 0.02     | 868     |
| accuracy     |           |        | 0.34     | 34675   |
| macro avg    | 0.29      | 0.28   | 0.27     | 34675   |
| weighted avg | 0.33      | 0.34   | 0.32     | 34675   |

Şekil 8.7 BERT İki Aşamalı Sınıflandırma F-1 Skor Sonuçları

Şekil 8.8 ve Şekil 8.9'daki karışıklık matrisleri kıyaslandığında 0 numaralı sınıftaki yığılmanın dağıldığı görülmektedir.





















Şekil 8.8 BERT Tek Aşamalı Sınıflandırma Confusion Matrix



Şekil 8.9 BERT İki Aşamalı Sınıflandırma Confusion Matrix

## 8.5 Emoji Tahminleri

Tüm modeller arasında 0.29 makro f-1 skoru ile GloVe gömme modeli kullanılan BLSTM modeli en yüksek başarımlarına sahiptir. Şekil 8.10'da BLSTM modelinin verilen cümlelere yapmış olduğu emoji tahminleri ve cümlelerin gerçek emojileri gösterilmektedir.

| Tweet   | True<br>Emoji   | Predicted<br>Emoji  |
|---|---|---|
| anna hopiefirst day nd grade kindestlittlegirl  |    |    |
| allcity dncinphl truthopwer spring garden   |    |    |
| i wish we wer in the same car yesterday saintshanda keep it going with the prayforamy |    |    |
| taking some time to mention our little unmentionables silk and beautiful piecs from   |    |    |
| good weeknd with great friends labordayweeknd river the tennessee river               |    |    |
| once agin netflix amp chill sundaybumday at aptments in san antonio tx                |    |    |
| happiness only a bucket awy all you got ta do call on the captain sunsoutrumsout      |  |  |
| summer rooftop new friends the best of old friends postgrad sae oldfriends            |  |  |
| its about to go down at the ultimate grilled chees cook off homeandpatio duval        |  |  |

Şekil 8.10 BLSTM Emoji Tahminleri

## 8.6 Emoji Sınıflarının Birleştirilmesi

Şekil 8.10'da verilen örneklere ve BLSTM, LSTM, BERT başlıkları altında verilen karışıklık matrislerine bakıldığında bazı emojiilerin sıkça birbiriyle karşılaştırıldığı görülmektedir. Örneğin Şekil 8.10'daki örnekte olduğu gibi flaşlı kamera (18) ve flaşsız kamera (10) emojiileri sıkça karıştırılmıştır. Aynı zamanda kırmızı kalp, mor kalp, mavi kalp, ikili kalp gibi ifade ettikleri anlam bakımından neredeyse aynı olan emojiiler de sıkça karıştırılmıştır. Buna örnek olarak Şekil 8.6'daki karışıklık matrisine bakıldığında 0 numaralı emoji için neredeyse kendisiyle aynı miktarda 3 numaralı emojiinin tahmin edildiğini görmekteyiz. Etiketlerin karşılık geldiği emojiiler Şekil 8.11'deki tablodan incelenebilir.

| 0  | 1  | 2  | 3  | 4  | 5  | 6  | 7  | 8  | 9  |
|----|----|----|----|----|----|----|----|----|----|
| ❤️ | 😄  | 😂  | ❤️ | 🔥  | 😊  | 😎  | 🌟  | 💙  | 😏  |
| 10 | 11 | 12 | 13 | 14 | 15 | 16 | 17 | 18 | 19 |
| 📷  | us | ☀️ | 💜  | 😊  | 🎉  | 😁  | 🎄  | 📷  | 😱  |

Şekil 8.11 Emoji Tablosu

Tahmin sırasında oluşan bu karmaşıklık nedeniyle, benzer anlam ifade eden emoji sınıflarının birleştirilerek tek sınıf altında toplanmasına karar verilmiştir. Sınıfların birleştirilmesinin ardından sınıfların ifade ettiği emojiiler Şekil 8.12'deki gibi düzenlenmiştir.

| 0       | 1  | 2  | 3 | 4 | 5 | 6 | 7 | 8  | 9 | 10 | 11 | 12 | 13 |
|---------|----|----|---|---|---|---|---|----|---|----|----|----|----|
| ❤️😄❤️💙💜 | 😂😁 | 📷📷 | 🔥 | 😊 | 😎 | 🌟 | 😏 | us | 😊 | 🎉  | 🎄  | 😱  | ☀️ |

Şekil 8.12 Düzenlenmiş Emoji Tablosu

İki Aşamalı Sınıflandırma uygulanan BERT modelinin sonuçları, düzenlenmiş sınıf üzerinden yeniden hesaplanmıştır. Modelde her bir class için elde edilmiş f-1 puanı Şekil 8.13'te görülmektedir.


Birleştirilmiş sınıflar ile uygulanan modelin makro f-1 puanı 0.34 olarak hesaplanmıştır.

14 sınıf ile iki aşamalı BERT modelinin karışıklık matrisi Şekil 8.14'te görülmektedir.

| Precision | Recall | F1 Score |
|-----------|--------|----------|
| 0.68      | 0.68   | 0.68     |
| 0.45      | 0.53   | 0.49     |
| 0.45      | 0.39   | 0.42     |
| 0.49      | 0.53   | 0.51     |
| 0.15      | 0.16   | 0.15     |
| 0.17      | 0.14   | 0.15     |
| 0.26      | 0.27   | 0.26     |
| 0.18      | 0.18   | 0.18     |
| 0.55      | 0.61   | 0.58     |
| 0.35      | 0.51   | 0.42     |
| 0.14      | 0.081  | 0.10     |
| 0.27      | 0.21   | 0.23     |
| 0.57      | 0.73   | 0.64     |
| 0.12      | 0.014  | 0.025    |

**Şekil 8.13** Birleştirilmiş Sınıflar ile BERT F-1 Skor Sonuçları





Şekil 8.14 Birleştirilmiş Sınıflar ile BERT Confusion Matrix

Bu bölümde kullanılan modellerin son sonuçları karşılaştırmalı bir şekilde incelenecektir.

### 9.1 GloVe

**Tablo 9.1** GloVe Gömme Modeli ile F-1 Skor Sonuçlarının Karşılaştırılması

|                  | ROS  |       | SMOTE |       | Aşırı Örneklemesiz |       |
|------------------|------|-------|-------|-------|--------------------|-------|
|                  | LSTM | BLSTM | LSTM  | BLSTM | LSTM               | BLSTM |
| 0                | 0.11 | 0.12  | 0.45  | 0.44  | 0.46               | 0.52  |
| 1                | 0.18 | 0.22  | 0.28  | 0.31  | 0.27               | 0.34  |
| 2                | 0.41 | 0.38  | 0.43  | 0.45  | 0.47               | 0.51  |
| 3                | 0.17 | 0.15  | 0.00  | 0.04  | 0.04               | 0.08  |
| 4                | 0.44 | 0.45  | 0.45  | 0.45  | 0.46               | 0.53  |
| 5                | 0.10 | 0.09  | 0.05  | 0.06  | 0.06               | 0.14  |
| 6                | 0.15 | 0.11  | 0.12  | 0.11  | 0.13               | 0.16  |
| 7                | 0.21 | 0.21  | 0.21  | 0.23  | 0.22               | 0.29  |
| 8                | 0.15 | 0.13  | 0.00  | 0.03  | 0.07               | 0.12  |
| 9                | 0.16 | 0.14  | 0.05  | 0.03  | 0.07               | 0.10  |
| 10               | 0.15 | 0.18  | 0.06  | 0.19  | 0.21               | 0.26  |
| 11               | 0.41 | 0.40  | 0.47  | 0.50  | 0.52               | 0.57  |
| 12               | 0.34 | 0.32  | 0.36  | 0.37  | 0.40               | 0.43  |
| 13               | 0.10 | 0.08  | 0.01  | 0.00  | 0.06               | 0.11  |
| 14               | 0.11 | 0.09  | 0.02  | 0.02  | 0.03               | 0.10  |
| 15               | 0.20 | 0.20  | 0.16  | 0.18  | 0.20               | 0.27  |
| 16               | 0.10 | 0.09  | 0.01  | 0.02  | 0.01               | 0.08  |
| 17               | 0.53 | 0.56  | 0.57  | 0.62  | 0.61               | 0.69  |
| 18               | 0.18 | 0.15  | 0.11  | 0.09  | 0.14               | 0.19  |
| 19               | 0.07 | 0.07  | 0.01  | 0.00  | 0.01               | 0.07  |
| <b>makro f-1</b> | 0.21 | 0.21  | 0.20  | 0.21  | 0.22               | 0.29  |

GloVe gömme modeli kullanılan modellerin iki ayrı aşırı örnekleme yapılarak ve aşırı örnekleme yapılmadığı durumlarda sınıf bazında elde ettiği f-1 skorlar Tablo 9.1’de verilmiştir.

Tablo 9.1’e bakıldığında aşırı örneklemesiz durumda sınıfların dağılımının dengesiz olmasından dolayı başarılar arasında açık farklar olduğu görülmüştür. Bu nedenle aşırı örnekleme ihtiyacı duyulmaktadır. Aşırı örnekleme için ROS ve SMOTE kullanılmıştır. SMOTE modelinde f-1 skoru 0.00 olan birçok sınıf bulunduğu görülmektedir. 13 (mor kalp) numaralı sınıfa bakıldığında aşırı örneklemesiz durumda f-1 skoru 0.06 olduğu fakat SMOTE uygulanarak 0.00’a düştüğü görülmektedir. Bunlar göz önünde bulundığında sınıflardaki dengesiz dağılımın SMOTE ile aşırı örnekleme uygulanarak giderilemediği söylenebilir.

Birçok sınıfta ROS ile aşırı örnekleme yapıldığı durumda SMOTE ile aşırı örnekleme yapıldığı durumdan daha başarılı sonuç elde edilmiştir. Örneğin 3 (iki kalp), 8 (mavi kalp) ve 9 (öpücük gönderen yüz) numaralı sınıflar ROS modelinde SMOTE modeline göre daha başarılıdır. Fakat iki örnekleme modeli için de dengesiz dağılımın beklenen düzeyde önüne geçemediği söylenebilir.

Modellere bakıldığında 2 (gözleri yaşlarla gülen yüz), 4 (alev), 11 (dalgin yüz), 17 (noel ağacı) numaralı sınıfların yüksek başarı oranına sahip olduğu görülmektedir. 17 numaralı sınıfın tüm modellerde başarı üstünlüğü sağladığını söyleyebiliriz. Bunun nedeni, içerisinde ‘christmas’ geçen tweetlerde genel olarak bu emojiinin kullanılması bu nedenle bu emojiyi tahmin etmenin diğer emojiye nazaran daha rahat yapılması olarak açıklanabilir.

4 (alev), 6 (güneş gözlüklü gülümseyen yüz), 14 (göz kırpan yüz) numaralı sınıflarda tüm aşırı örnekleme şekillerinin yakın başarılarla sahip olduğunu söylenebilir. ROS modeli göz ardı edilirse 0 (kırmızı kalp) numaralı sınıfın başarısının yüksek olduğu görülmektedir. Bunun nedeni veri setinde kalp emoji içeren tweetlerin daha baskın bulunması olarak açıklanabilir.

5 (gülümseyen gözlerle gülümseyen yüz), 13 (mor kalp), 14 (göz kırpan yüz) ve 19 (dil çıkaran göz kırpan yüz) numaralı sınıfların başarı oranlarının oldukça düşük olduğu görülmektedir. Bunun nedeni bu emojiilerin anlam bakımından benzer olan diğer emojiilerle karıştırılmasıdır. Örneğin 13 (mor kalp) numaralı emoji sıkça 0 (kırmızı kalp), 1 (gözleri kalp şeklinde gülen yüz), 3 (iki kalp) ve 8 (öpücük gönderen yüz) numaralı sınıflarla karıştırılmıştır.

Tüm modeller arasında en başarılı modelin aşırı örneklemesiz BLSTM modeli olduğu görülmektedir.

## 9.2 Keras

Keras gömme modeli kullanılan modellerin iki ayrı aşırı örnekleme yapılarak ve aşırı örnekleme yapılmadığı durumlarda sınıf bazında elde ettiği f-1 skorlar Tablo 9.1’de verilmiştir.

**Tablo 9.2** Keras Gömme Modeli ile F-1 Skor Sonuçlarının Karşılaştırılması

|                  | ROS  |       | SMOTE |       | Aşırı Örneklemesiz |       |
|------------------|------|-------|-------|-------|--------------------|-------|
|                  | LSTM | BLSTM | LSTM  | BLSTM | LSTM               | BLSTM |
| 0                | 0.15 | 0.01  | 0.44  | 0.44  | 0.44               | 0.45  |
| 1                | 0.12 | 0.18  | 0.12  | 0.21  | 0.18               | 0.23  |
| 2                | 0.35 | 0.36  | 0.40  | 0.40  | 0.41               | 0.41  |
| 3                | 0.15 | 0.16  | 0.04  | 0.02  | 0.00               | 0.00  |
| 4                | 0.40 | 0.41  | 0.40  | 0.41  | 0.45               | 0.46  |
| 5                | 0.10 | 0.11  | 0.03  | 0.04  | 0.06               | 0.05  |
| 6                | 0.13 | 0.13  | 0.09  | 0.06  | 0.13               | 0.13  |
| 7                | 0.19 | 0.17  | 0.17  | 0.19  | 0.19               | 0.18  |
| 8                | 0.12 | 0.12  | 0.02  | 0.02  | 0.00               | 0.00  |
| 9                | 0.11 | 0.13  | 0.03  | 0.04  | 0.00               | 0.00  |
| 10               | 0.20 | 0.20  | 0.16  | 0.10  | 0.24               | 0.23  |
| 11               | 0.47 | 0.43  | 0.43  | 0.40  | 0.55               | 0.54  |
| 12               | 0.31 | 0.30  | 0.30  | 0.32  | 0.36               | 0.38  |
| 13               | 0.11 | 0.11  | 0.02  | 0.00  | 0.00               | 0.00  |
| 14               | 0.06 | 0.07  | 0.05  | 0.05  | 0.01               | 0.00  |
| 15               | 0.18 | 0.19  | 0.07  | 0.10  | 0.16               | 0.10  |
| 16               | 0.08 | 0.08  | 0.00  | 0.00  | 0.00               | 0.00  |
| 17               | 0.53 | 0.52  | 0.50  | 0.54  | 0.61               | 0.63  |
| 18               | 0.17 | 0.16  | 0.08  | 0.17  | 0.00               | 0.01  |
| 19               | 0.06 | 0.05  | 0.02  | 0.01  | 0.00               | 0.00  |
| <b>makro f-1</b> | 0.20 | 0.19  | 0.17  | 0.18  | 0.19               | 0.19  |

Tablo 9.2’ye bakıldığında Keras modelinde de GloVe modeline benzer skor oranları görülmektedir. Başarılı ve başarısız olduğu sınıflar hemen hemen aynıdır. Keras modelinin genel olarak Word2Vec ve GloVe modellerinden daha düşük başarıya sahip olduğu söylenebilir.

LSTM modelinde 0.00 skora sahip olan bazı sınıfların SMOTE ile artırıldığı görülmektedir.

Tüm modeller arasında en başarılı modelin ROS kullanılan LSTM modeli olduğu görülmektedir.

### 9.3 Word2Vec

**Tablo 9.3** Word2Vec Gömme Modeli ile F-1 Skor Sonuçlarının Karşılaştırılması

|                  | ROS  |       | SMOTE |       | Aşırı Örneklemesiz |       |
|------------------|------|-------|-------|-------|--------------------|-------|
|                  | LSTM | BLSTM | LSTM  | BLSTM | LSTM               | BLSTM |
| 0                | 0.14 | 0.15  | 0.44  | 0.42  | 0.45               | 0.46  |
| 1                | 0.20 | 0.21  | 0.26  | 0.30  | 0.22               | 0.27  |
| 2                | 0.38 | 0.34  | 0.43  | 0.46  | 0.44               | 0.45  |
| 3                | 0.15 | 0.13  | 0.02  | 0.07  | 0.00               | 0.02  |
| 4                | 0.43 | 0.43  | 0.44  | 0.42  | 0.47               | 0.47  |
| 5                | 0.09 | 0.09  | 0.07  | 0.07  | 0.03               | 0.05  |
| 6                | 0.11 | 0.13  | 0.08  | 0.10  | 0.13               | 0.12  |
| 7                | 0.19 | 0.22  | 0.19  | 0.25  | 0.20               | 0.24  |
| 8                | 0.14 | 0.14  | 0.01  | 0.04  | 0.04               | 0.06  |
| 9                | 0.17 | 0.16  | 0.06  | 0.04  | 0.04               | 0.03  |
| 10               | 0.10 | 0.18  | 0.19  | 0.18  | 0.15               | 0.23  |
| 11               | 0.41 | 0.44  | 0.38  | 0.48  | 0.49               | 0.50  |
| 12               | 0.32 | 0.32  | 0.35  | 0.39  | 0.38               | 0.40  |
| 13               | 0.10 | 0.09  | 0.00  | 0.00  | 0.07               | 0.07  |
| 14               | 0.10 | 0.08  | 0.02  | 0.03  | 0.02               | 0.04  |
| 15               | 0.17 | 0.18  | 0.14  | 0.17  | 0.17               | 0.19  |
| 16               | 0.10 | 0.10  | 0.01  | 0.03  | 0.01               | 0.02  |
| 17               | 0.57 | 0.53  | 0.54  | 0.60  | 0.60               | 0.63  |
| 18               | 0.17 | 0.13  | 0.06  | 0.09  | 0.11               | 0.07  |
| 19               | 0.08 | 0.07  | 0.02  | 0.00  | 0.00               | 0.01  |
| <b>makro f-1</b> | 0.21 | 0.21  | 0.18  | 0.21  | 0.20               | 0.22  |

Tablo 9.3'e bakıldığında Word2Vec modelinde de diğer iki modele benzer skor oranları görülmektedir. Başarılı ve başarısız olduğu sınıflar hemen hemen aynıdır. Word2Vec gömme modeli GloVe gömme modeliyle oldukça yakın başarı oranlarına sahip olmuştur.

Tüm modeller arasında en başarılı modelin aşırı örneklemesiz BLSTM modeli olduğu görülmektedir.

## 9.4 BERT

**Tablo 9.4** BERT ile F-1 Skor Sonuçlarının Karşılaştırılması

|                      | ROS  | Aşırı<br>Örnekleme |
|----------------------|------|--------------------|
| 0                    | 0.31 | 0.48               |
| 1                    | 0.28 | 0.32               |
| 2                    | 0.45 | 0.51               |
| 3                    | 0.18 | 0.03               |
| 4                    | 0.47 | 0.52               |
| 5                    | 0.14 | 0.13               |
| 6                    | 0.16 | 0.15               |
| 7                    | 0.21 | 0.26               |
| 8                    | 0.14 | 0.07               |
| 9                    | 0.14 | 0.07               |
| 10                   | 0.24 | 0.28               |
| 11                   | 0.56 | 0.59               |
| 12                   | 0.39 | 0.44               |
| 13                   | 0.13 | 0.08               |
| 14                   | 0.11 | 0.08               |
| 15                   | 0.23 | 0.25               |
| 16                   | 0.10 | 0.03               |
| 17                   | 0.60 | 0.62               |
| 18                   | 0.22 | 0.11               |
| 19                   | 0.07 | 0.00               |
| <b>makro<br/>f-1</b> | 0.26 | 0.25               |

BERT modelinde hemen hemen tüm sınıfların f-1 skorlarının LSTM ve BLSTM'e oranla arttığını görmekteyiz. Aynı zamanda başarı oranı 0.00 olan sınıf sayısı diğer modellere göre daha azdır ve bu sınıflar da aşırı örnekleme ile düzeltilmiştir.

Başarılı ve başarısız sınıfların dağılımı bir önceki modellerle benzerlik göstermektedir.

ROS kullanılan modelin daha başarılı olduğu görülmektedir.

## 9.5 İki Aşamalı Sınıflandırma

**Tablo 9.5** İki Aşamalı Sınıflandırma ile F-1 Skor Sonuçlarının Karşılaştırılması

|                  | <b>LSTM</b> | <b>BLSTM</b> | <b>BERT</b> |
|------------------|-------------|--------------|-------------|
| <b>0</b>         | 0.29        | 0.31         | 0.41        |
| <b>1</b>         | 0.29        | 0.31         | 0.32        |
| <b>2</b>         | 0.45        | 0.43         | 0.49        |
| <b>3</b>         | 0.19        | 0.19         | 0.19        |
| <b>4</b>         | 0.42        | 0.47         | 0.51        |
| <b>5</b>         | 0.14        | 0.14         | 0.15        |
| <b>6</b>         | 0.14        | 0.14         | 0.15        |
| <b>7</b>         | 0.22        | 0.25         | 0.26        |
| <b>8</b>         | 0.10        | 0.13         | 0.16        |
| <b>9</b>         | 0.15        | 0.14         | 0.17        |
| <b>10</b>        | 0.23        | 0.24         | 0.29        |
| <b>11</b>        | 0.49        | 0.50         | 0.58        |
| <b>12</b>        | 0.40        | 0.39         | 0.42        |
| <b>13</b>        | 0.05        | 0.07         | 0.08        |
| <b>14</b>        | 0.03        | 0.02         | 0.10        |
| <b>15</b>        | 0.24        | 0.20         | 0.23        |
| <b>16</b>        | 0.02        | 0.01         | 0.04        |
| <b>17</b>        | 0.61        | 0.64         | 0.64        |
| <b>18</b>        | 0.06        | 0.07         | 0.18        |
| <b>19</b>        | 0.00        | 0.00         | 0.02        |
| <b>makro f-1</b> | 0.23        | 0.27         | 0.27        |

Tablo 9.5'e bakıldığında iki aşamalı sınıflandırma modellerinde 0.00 sonuç veren sınıfların neredeyse yok denecek kadar azaldığını görmekteyiz. Aynı şekilde sınıflar arasındaki başarı farkı da diğer modellere göre daha düşüktür. İki aşamalı sınıflandırma uygulamasının genel olarak modellerin başarısını artırdığı da söylenebilir.

0 numaralı sınıfın başarısını bir miktar düşürmesine karşın diğer birçok sınıfta daha başarılı bir sınıflandırma yaptığı ve 0 numaralı sınıftaki yığılmanın büyük oranda dağıldığı söylenebilir.

İstisna olarak 19 (dil çıkararak gülümseyen yüz) sınıfın başarısı diğer modellerde olduğu gibi 0'a yakındır. Bunun nedeni bu sınıfın örnek sayısı en düşük olan sınıf olmasıdır.

Bu 3 model içerisinde BLSTM ve BERT başarılı olmuşlardır.

## 9.6 Değerlendirme

Genel sonuçlara bakıldığında gömme modeli olarak GloVe gömme modelinin, aşırı örnekleme durumun ve modeller arasında ise BLSTM ve BERT modellerinin daha yüksek başarıya sahip olduğu söylenebilir. Ayrıca aşırı örnekleme yöntemleri arasından ROS'un SMOTE'a göre daha yüksek başarıya sahip olduğu görülmüştür.

| ENGLISH            |              |              |              |              |
|--------------------|--------------|--------------|--------------|--------------|
| Team               | F1           | Prec.        | Recall       | Acc.         |
| Tübingen-Oslo      | <b>35.99</b> | 36.55        | 36.22        | 47.09        |
| NTUA-SLP           | 35.36        | 34.53        | <b>38.00</b> | 44.74        |
| hgsgnlp            | 34.02        | 35           | 33.57        | 45.55        |
| EmoNLP             | 33.67        | 39.43        | 33.7         | <b>47.46</b> |
| ECNU               | 33.35        | 35.17        | 33.11        | 46.3         |
| UMDuluth-CS8761    | 31.83        | <b>39.80</b> | 31.37        | 45.73        |
| BASELINE           | 30.98        | 30.34        | 33           | 42.56        |
| THU_NGN            | 30.25        | 31.85        | 29.81        | 42.18        |
| TAJEB              | 30.13        | 29.91        | 33.02        | 38.09        |
| Emojilt            | 29.5         | 35.17        | 29.91        | 39.21        |
| Reborn             | 29.24        | 33.67        | 28.94        | 42.43        |
| freeze             | 29.13        | 31.54        | 29.23        | 37.14        |
| csy                | 28.93        | 31.12        | 29           | 36.85        |
| Nova               | 27.89        | 28.49        | 28.2         | 34.83        |
| Sheffield          | 27.18        | 28.57        | 26.61        | 37.69        |
| YNU-HPCC           | 26.89        | 26.97        | 29.71        | 32.53        |
| mboyanov           | 26.77        | 32.82        | 27.42        | 36.79        |
| kaka manData       | 26.59        | 30           | 26.97        | 36.34        |
| Duluth UROP        | 26.59        | 27.18        | 27.87        | 33.8         |
| CENNLP             | 26.45        | 31.62        | 26.87        | 41.18        |
| UMDSUB             | 25.99        | 33.01        | 26.71        | 41           |
| THU_HCSI           | 25.83        | 32.38        | 25.9         | 35.34        |
| Peperomia          | 25.68        | 28.98        | 26.04        | 35.34        |
| MMU - Computing    | 24.98        | 28.94        | 25.04        | 34.59        |
| NoEmotionsAttached | 23.3         | 25.27        | 24.47        | 32.76        |
| PickleTeam!        | 22.86        | 26.17        | 24.37        | 34.09        |
| Reborn             | 21.97        | 26.52        | 22.06        | 30.64        |
| PALM_gzy           | 21.97        | 26.52        | 22.06        | 30.64        |
| #TeamINF           | 21.5         | 26.21        | 20.84        | 31.59        |
| Hatching Chick     | 21.44        | 25.97        | 21.48        | 36.52        |
| CORAL              | 21.35        | 32.82        | 22.48        | 34.05        |
| Meisele            | 20.02        | 25.74        | 19.54        | 30.71        |
| erai               | 19.96        | 22.1         | 19.62        | 28.36        |
| SBIG               | 19.44        | 25.41        | 16.12        | 19.84        |
| The Dabblers       | 18.92        | 25.02        | 18.96        | 30.45        |
| ART @ Tor Vergata  | 18.39        | 24.49        | 17.25        | 29.45        |
| Amrita_CEN_NLP1    | 17.96        | 19.47        | 17.75        | 24.41        |
| Lips Eggplant      | 17.69        | 21.81        | 17.19        | 26.81        |
| XSSX               | 16.45        | 31.56        | 16.77        | 30.99        |
| Kno.e.sis          | 14.42        | 18.72        | 18.49        | 18.99        |
| thelonewolf190694  | 14.21        | 13.66        | 17.35        | 30.7         |
| LIS                | 13.53        | 25.58        | 14.14        | 29.42        |
| uaic2018           | 11.06        | 13.65        | 11.24        | 19.61        |
| jogonba2           | 8.52         | 24.16        | 9.51         | 25.6         |
| SBIG2              | 6.44         | 18.76        | 8.49         | 12.64        |
| alsu.wh            | 3.73         | 4.38         | 5.06         | 9.83         |
| Innovating world   | 3.09         | 18.47        | 5.73         | 22.74        |
| hjpwhu             | 2.04         | 2.63         | 3.22         | 3.92         |

Şekil 9.1 Yarışmaya Katılan Diğer Takımların F-1 Skorları

Projemizde en yüksek makro ortalama f-1 skor 0.29 olarak elde edilmiştir. Şekil 9.1'a bakıldığında projemizde elde edilen sonucun 13. sırada olduğunu görmekteyiz.



## Referanslar

---

- [1] (), [Online]. Available: <https://www.oracle.com/tr/artificial-intelligence/what-is-natural-language-processing/> (visited on 05/01/2023).
- [2] (), [Online]. Available: <https://ittutorial.org/dogal-dil-isleme-ve-morfolojik-analiz-2/> (visited on 06/16/2023).
- [3] A. E. ÖZMUTLU, “Doğal dil İşleme,” *Bilgisayar Bilimlerinde Teorik Ve Uygulamalı Araştırmalar*, vol. 129, 2021.
- [4] (), [Online]. Available: <https://yapayzeka.itu.edu.tr/arastirma/dogal-dil-isleme> (visited on 05/01/2023).
- [5] A. G. T. E. Sayar, “Dijitalleşen dil: Emojî ve kısaltmalar dilimizi deęiş (geliş) tirecek mi?” *İletişim Çağında Dijital Kültür*, p. 37, 2019.
- [6] N. ÇALIŞKAN and R. Yeşil, “Eğitim sürecinde öğretmenin beden dili,” *Ahi Evran Üniversitesi Kırşehir Eğitim Fakültesi Dergisi*, vol. 6, no. 1, pp. 199–207, 2005.
- [7] A. Onan, “Twitter mesajları üzerinde makine öğrenmesi yöntemlerine dayalı duygu analizi,” *Yönetim Bilişim Sistemleri Dergisi*, vol. 3, no. 2, pp. 1–14, 2017, ISSN: 2630-550X.
- [8] (), [Online]. Available: <https://competitions.codalab.org/competitions/17344#participate> (visited on 05/01/2023).
- [9] (), [Online]. Available: <https://eliozrumeysa.medium.com/nlp-ile-metin-verisi-%C3%B6n-i%CC%87%C5%9Fleme-9c852b6deb3> (visited on 05/01/2023).
- [10] (), [Online]. Available: <https://medium.com/bili%C5%9C%9Fim-hareketi/word-embedding-teknikleri-word2vec-nedir-tf-idf-nedir-e2f826dd9178> (visited on 05/01/2023).
- [11] (), [Online]. Available: <https://simgeerek.medium.com/kredi-kart%C4%B1-doland%C4%B1r%C4%B1c%C4%B1l%C4%B1k-tespiti-veri-setindeki-dengesizli%C4%9Fin-i%CC%87ncelenmesi-efde5436c7f6> (visited on 05/01/2023).
- [12] (), [Online]. Available: [https://tr.wikipedia.org/wiki/Uzun\\_k%C4%5C%B1sa\\_s%C3%5C%BCreli\\_bellek#:~:text=S%C4%5C%B1radan%C5%20bir%C5%20LSTM%C5%20%C3%5C%BCnitesi%C5%20bir,ve%C5%20%C3%5C%A7%C4%5C%B1kan%C5%20bilgi%C5%20ak%C4%5C%B1%C5%9F%C4%5C%B1n%C4%5C%B1%C5%20d%C3%5C%BCzenler](https://tr.wikipedia.org/wiki/Uzun_k%C4%5C%B1sa_s%C3%5C%BCreli_bellek#:~:text=S%C4%5C%B1radan%C5%20bir%C5%20LSTM%C5%20%C3%5C%BCnitesi%C5%20bir,ve%C5%20%C3%5C%A7%C4%5C%B1kan%C5%20bilgi%C5%20ak%C4%5C%B1%C5%9F%C4%5C%B1n%C4%5C%B1%C5%20d%C3%5C%BCzenler). (visited on 06/13/2023).

- [13] (), [Online]. Available: <https://medium.com/deep-learning-turkiye/uzun-k%C4%B1sa-vadeli-bellek-lstm-b018c07174a3> (visited on 05/01/2023).
- [14] (), [Online]. Available: <https://mfakca.medium.com/lstm-nedir-nas%C4%B1l-%C3%A7al%C4%B1%C5%9F%C4%B1r-326866fd8869> (visited on 06/13/2023).
- [15] (), [Online]. Available: <https://medium.com/@raghavaggarwal0089/bi-lstm-bc3d68da8bd0> (visited on 06/13/2023).
- [16] (), [Online]. Available: <https://medium.com/@toprakucar/bert-modeli-ile-t%C3%BCrk%C3%A7e-metinlerde-s%C4%B1n%C4%B1fland%C4%B1rma-yapmak-260f15a65611> (visited on 06/13/2023).
- [17] (), [Online]. Available: <https://iq.opengenus.org/embeddings-in-bert/> (visited on 06/15/2023).
- [18] (), [Online]. Available: <https://medium.com/@muhammedbuyukkinaci/word2vec-nedir-t%C3%BCrk%C3%A7e-f0cfab20d3ae> (visited on 06/17/2023).
- [19] (), [Online]. Available: <https://medium.com/codable/word2vec-fasttext-glove-d4402fa8cce0> (visited on 06/17/2023).
- [20] (), [Online]. Available: <https://github.com/stanfordnlp/GloVe> (visited on 06/17/2023).

### BİRİNCİ ÜYE

**İsim-Soyisim:** Beyda Güler  
**Doğum Tarihi ve Yeri:** 12.11.2001, Kastamonu  
**E-mail:** beyda.guler@yildiz.edu.tr  
**Telefon:** 0553 028 36 36  
**Staj Tecrübeleri:** Robotik

### İKİNCİ ÜYE

**İsim-Soyisim:** Şeymanur Korkmaz  
**Doğum Tarihi ve Yeri:** 04.10.2002, İstanbul  
**E-mail:** seymanur.korkmaz@yildiz.edu.tr  
**Telefon:** 0537 497 01 87  
**Staj Tecrübeleri:** Robotik

### Proje Sistem Bilgileri

**Sistem ve Yazılım:** Windows İşletim Sistemi, Python  
**Gerekli RAM:** 2GB  
**Gerekli Disk:** 256MB